

BİLGİSAYAR MÜHENDİSLİĞİ PROJESİ

1. YAPAY ZEKA TABANLI UYKU ANALİZİ İLE KALP KRİZİ RİSKİ TAHMİNİ

2. AMAÇ

Bu projenin temel amacı, bireylerin uyku sırasında kaydedilen fizyolojik verilerini, özellikle polisomnografi (PSG) sinyallerinden elde edilen çoklu parametreleri kullanarak, kalp krizi riskini erken aşamada ve non-invaziv bir yöntemle tahmin edebilen bir yapay zeka (YZ) modeli geliştirmektir. Günümüzde kalp krizi risk değerlendirmesi, çoğunlukla semptomlar belirginleştikten sonra veya maliyetli ve bazen invaziv olabilen tanısal testler aracılığıyla gerçekleştirilmektedir. Bu durum, erken müdahale fırsatlarının kaçırılmasına ve dolayısıyla morbidite ve mortalite oranlarının yüksek kalmasına neden olabilmektedir. Proje, uyku kalitesi ve fizyolojisindeki bozulmaların, kardiyovasküler hastalıklar (KVH) için önemli ve bağımsız bir risk faktörü olduğu yönündeki güçlü bilimsel kanıtlardan yola çıkmaktadır.¹ Özellikle, uyku yoksunluğunun yüksek tansiyon, inflamasyon, stres hormonu seviyelerinde artış ve olumsuz metabolik değişiklikler gibi kalp sağlığını doğrudan etkileyen durumlara yol açabileceği bilinmektedir.¹ Benzer şekilde, uyku apnesi gibi spesifik uyku bozukluklarının, gece boyunca tekrarlayan oksijen düşüşleri (hipoksi) ve kan basıncı yükselmeleri yoluyla kalp damarlarına zarar vererek kalp krizi riskini ciddi oranda artırdığı gösterilmiştir.³ Bu proje, bu tür uykuya ilişkili risk faktörlerini proaktif bir şekilde belirleyerek, geleneksel risk değerlendirme yöntemlerindeki boşlukları doldurmayı hedeflemektedir.

Proje ile çözülmesi hedeflenen ana problem, kalp krizi gibi yaşamı tehdit eden kardiyovasküler olayların erken teşhisindeki mevcut zorluklar ve yetersizliklerdir. Geliştirilecek YZ tabanlı sistem, bireylerin genellikle farkında olmadığı, uyku sırasında ortaya çıkan ve kardiyak riskle ilişkili olabilecek fizyolojik örüntüleri ve anormallikleri tespit etmeyi amaçlamaktadır. Bu sayede, yüksek riskli bireylerin erken saptanması ve kişiselleştirilmiş önleyici tedbirlerin (örneğin yaşam tarzı değişiklikleri, daha yakın tıbbi takip veya spesifik tedaviler) zamanında alınmasına olanak tanınacaktır. Bu yaklaşım, sağlık hizmetlerinde reaktif (olay sonrası tedavi) bir modelden, proaktif (risklerin önceden belirlenip yönetilmesi) bir modele geçişi desteklemektedir.

Projenin uzun vadeli etkisi, kalp krizi insidansını ve buna bağlı ölüm oranlarını azaltmaya yardımcı olmak, bireylerin yaşam kalitesini artırmak ve sağlık hizmetleri üzerindeki yükü hafifletmektir. Erken risk tespiti, daha az invaziv ve daha düşük maliyetli müdahalelerle potansiyel olarak yıkıcı sağlık sorunlarının önüne geçilmesini sağlayarak hem bireysel hem de toplumsal düzeyde önemli ekonomik faydalar sunabilir. Geliştirilecek sistem, gelecekte giyilebilir teknolojiler veya evde uyku testi cihazları ile entegre edilerek, geniş kitlelere ulaşabilir, erişilebilir ve kullanıcı dostu bir erken uyarı sistemi potansiyeli taşımaktadır. Bu, özellikle sağlık hizmetlerine erişimin kısıtlı olduğu bölgelerde veya düzenli sağlık kontrolü yaptırma alışkanlığı düşük bireyler için değerli olabilir.

Bu proje, uyku verilerinin kardiyovasküler risk değerlendirmesinde henüz yeterince ve etkin bir şekilde kullanılmamasından kaynaklanan önemli bir boşluğu doldurmayı amaçlamaktadır. Yapay zekanın, karmaşık tıbbi verileri analiz etme, gizli örüntüleri ortaya çıkarma ve hastalık tahmininde devrim niteliğinde yenilikler getirme potansiyeli büyüktür.⁴ YZ'nin sağlık hizmetleri verilerini analiz ederek hastalık örüntülerini anlama ve kaynak tahsisini optimize etme yeteneği, bu projenin daha geniş sağlık sistemi etkilerine de işaret etmektedir.⁶ Dolayısıyla bu çalışma, YZ'nin uyku tıbbi ve kardiyoloji kesişimindeki potansiyelini somut bir şekilde ortaya koyarak, hem bilimsel literatüre hem de pratik uygulamalara katkıda bulunmayı hedeflemektedir.

3. HEDEFLER

Hedef 1: Kapsamlı Bir Literatür Taraması ve Veri Seti Belirleme

- Uyku fizyolojisi, kalp krizi patofizyolojisi, uyku bozukluklarının (özellikle uyku apnesi, uyku bölünmeleri) kardiyovasküler sistem üzerindeki etkileri ve yapay zekanın bu alandaki güncel uygulamaları üzerine derinlemesine ve sistematik bir literatür taraması yapmak.
- Kalp krizi riski tahmini için uygun, halka açık veya proje kapsamında erişilebilir, yeterli büyüklükte ve kalitede polisomnografi (PSG) veri setlerini (örneğin, PhysioNet platformu üzerinde yer alan Sleep Heart Health Study (SHHS)⁷, Computing in Cardiology (CinC) Challenge 2018 veri setleri⁸) belirlemek, bu veri setlerinin içeriklerini, etiket bilgilerini ve kullanım koşullarını detaylı bir şekilde incelemek ve erişim sağlamak. PhysioNet/CinC Challenge 2018 veri seti, 1983 PSG kaydı içermekte ve EEG, EOG, EMG, EKG, SaO2 gibi çeşitli fizyolojik sinyalleri barındırmaktadır; bu veri seti özellikle uyku bölünmelerinin (arousals) etiketlenmiş olması açısından değerlidir.⁸ SHHS veri seti ise 5000'den fazla katılımcıdan toplanmış uyku kayıtlarını içermesiyle ve özellikle SpO2 sinyallerinin analizi için zengin bir kaynak sunmasıyla öne çıkmaktadır.⁷
- **Başarı Kriteri:** Konuyla ilgili en az 20 adet hakemli bilimsel makalenin detaylı bir şekilde incelenip özetlenmesi. Kalp krizi riski tahmini analizleri için en az bir adet büyük ölçekli (örneğin, 1000'den fazla bireye ait kayıt içeren) ve çoklu PSG sinyallerini barındıran veri setinin temin edilmesi ve kullanıma hazır hale getirilmesi.
- **Hedef 2: Veri Ön İşleme ve Öznitelik Mühendisliği Süreci**(Seçilen PSG veri setlerindeki ham fizyolojik sinyalleri (EKG, SpO2, EEG, EOG, EMG, solunum sinyalleri vb.) gürültüden arındırmak (örneğin, güç hattı gürültüsü, hareket artefaktları), temel çizgi kaymalarını düzeltmek ve sinyalleri standart formatlara dönüştürmek için uygun dijital filtreleme ve sinyal işleme tekniklerini uygulamak.
- Uyku evrelerini (Uyanıklık, N1, N2, N3, REM) belirlemek amacıyla, veri setinde mevcutsa uzman skorlamalarını kullanmak veya bu skorlamalar yoksa ya da tutarlılıklarını artırmak için literatürde kabul görmüş otomatik uyku evreleme algoritmalarını (örneğin, YASA kütüphanesi veya basit bir derin öğrenme modeli)

uygulamak.⁸

- Kalp Atım Hızı Değişkenliği (HRV) metriklerini (zaman domen: SDNN, RMSSD, pNN50; frekans domen: LF, HF, LF/HF oranı vb.) EKG sinyallerinden, farklı uyku evrelerine spesifik olarak veya tüm uyku periyodu için çıkarmak. Uyku HRV'sinin, özellikle HF (yüksek frekans) bileşeninin, uzun vadeli kardiyovasküler hastalık sonuçları için bağımsız bir belirleyici olduğu ve XGBoost gibi modellerle %75.3 civarında bir doğrulukla tahminleme yapılabildiği gösterilmiştir.¹⁰ Bu nedenle, SDNN, RMSSD, LF, HF, HFnorm ve TP gibi spesifik HRV metriklerinin çıkarılması hedeflenmektedir.¹⁰
- Kan oksijen saturasyonu (SpO2) dinamiklerini (ortalama SpO2, minimum SpO2, desaturasyon olayları, Oksijen Desaturasyon İndeksi - ODI, %90 altındaki süre - T90 vb.) analiz etmek. Giyilebilir sensörlerden elde edilen SpO2 sinyallerinin dahi uyku apnesi tespiti ve ciddiyet sınıflandırması için kullanılabileceği ve ODI gibi geleneksel SpO2 belirteçlerinin önemini koruduğu belirtilmiştir.⁷
- Solunum olayları (apne, hipopne), uyku bölünmeleri (arousals) ve periyodik bacak hareketleri gibi diğer ilgili fizyolojik olaylardan kantitatif öznitelikler çıkarmak.
- **Başarı Kriteri:** Temizlenmiş ve işlenmiş veri seti üzerinde, kalp krizi riskiyle ilişkili olabileceği düşünülen en az 50 farklı ve anlamlı fizyolojik öznitelik içeren bir öznitelik matrisinin oluşturulması. Tüm veri ön işleme ve öznitelik çıkarım süreçlerinin otomatikleştirilmiş bir yazılım sürecinde (script/kod dizisi) toplanarak tekrarlanabilirliğin sağlanması.
- **Hedef 3: Yapay Zeka Modelleri Geliştirme ve Eğitim**
 - Kalp krizi riskini (veya veri setinde mevcutsa ilişkili birincil sonlanım noktası, örneğin majör advers kardiyak olaylar - MACE) tahmin etmek amacıyla, literatürde etkinliği kanıtlanmış çeşitli makine öğrenmesi (ML) algoritmalarını (örneğin, Lojistik Regresyon, Destek Vektör Makineleri (SVM), Rastgele Orman (Random Forest), XGBoost¹⁰) ve derin öğrenme (DL) mimarilerini (örneğin, Evrişimli Sinir Ağları (CNN), Tekrarlayan Sinir Ağları (RNN/LSTM), Transformer tabanlı modeller veya bu mimarilerin hibrit kombinasyonları¹²) tasarlamak, uygulamak ve eğitmek. Özellikle, OSA ilişkili hipertansiyon tahmini için Gradient Boosting Machine (GBM) modelinin %87.3 AUC ve %88.5 doğrulukla başarılı olduğu¹¹, PSG verileri için 1D-CNN ve RNN gibi modellerin uygun olduğu ve PSG-MAE gibi ön-eğitilmiş çerçevelerin uyku evrelemede %83.7, OSA tespitinde ise %90.45 doğruluk sağlayabildiği¹³ ve CNN-Transformer hibrit modellerinin yerel ve global özellikleri bir arada yakalayarak kalp hastalığı tahmininde geleneksel modellere göre daha üstün performans gösterebildiği¹⁴ dikkate alınacaktır.
 - Veri setini, modelin genelleme yeteneğini objektif bir şekilde değerlendirebilmek için eğitim, doğrulama (validation) ve test alt kümelerine uygun oranlarda (örneğin, %70-%15-%15) ve katılımcı düzeyinde (aynı katılımcıya ait verilerin farklı kümelerde yer almaması prensibiyle) bölmek.
 - Modellerin performansını artırmak ve aşırı öğrenmeyi (overfitting) azaltmak için k-

katmanlı çapraz doğrulama (cross-validation) tekniklerini eğitim ve doğrulama süreçlerinde uygulamak.

- Seçilen modellerin hiperparametrelerini (örneğin, öğrenme oranı, ağaç sayısı, katman derinliği, nöron sayısı vb.) sistematik olarak optimize etmek için Grid Search, Random Search veya Bayesian Optimizasyon gibi teknikler kullanmak.
- **Başarı Kriteri:** En az üç farklı temel yapay zeka modelinin (bunlardan en az bir tanesi derin öğrenme modeli olmak üzere) başarıyla geliştirilmesi, eğitilmesi ve hiperparametrelerinin optimize edilmesi. Tüm eğitim süreçlerinin detaylı bir şekilde belgelenmesi ve tekrarlanabilirliğinin sağlanması.

- **Hedef 4: Model Performansını Değerlendirme ve Karşılaştırma**

- Geliştirilen ve eğitilen yapay zeka modellerinin kalp krizi riski tahmin performansını, daha önce ayrılmış ve modelin eğitim/doğrulama aşamalarında hiç görmediği kör test veri seti üzerinde kapsamlı bir şekilde değerlendirmek.
- Modellerin performansını ölçmek için standart ve probleme uygun sınıflandırma metriklerini kullanmak: Doğruluk (Accuracy), Kesinlik (Precision), Duyarlılık (Recall/Sensitivity), F1-Skoru, ROC Eğrisi Altındaki Alan (AUC-ROC) ve Özgüllük (Specificity).¹⁰ Yapılan çalışmalarda, YZ modellerinin EKG verilerinden tıkalı koroner arterleri saptamada %0.91 AUC ¹⁶ gibi yüksek değerlere ulaşabildiği ve kalp yetmezliği tanısında %86.7 ile %99.9 arasında değişen doğruluklar ve %97'yi aşan duyarlılık/özgüllük değerleri bildirdiği ¹⁷ göz önüne alındığında, bu projede de yüksek performans hedeflenecektir.
- Farklı modellerin (geleneksel ML modelleri vs. DL modelleri, farklı DL mimarileri kendi içinde) performanslarını bu metrikler bazında objektif olarak karşılaştırmak ve en iyi performansı gösteren modeli (veya modelleri) belirlemek. Bu modelin kalp krizi riskini tahmin etme doğruluğunun (veya tercihen AUC-ROC değerinin) %80'in (AUC > 0.80) üzerinde olmasını hedeflemek.
- **Başarı Kriteri:** En iyi performansı gösteren modelin, test veri seti üzerinde önceden belirlenmiş performans eşiklerini (örneğin, AUC-ROC > 0.80, Duyarlılık > 0.75) karşılaması. Tüm değerlendirme sonuçlarının tablolar, grafikler (ROC eğrileri, Precision-Recall eğrileri vb.) ve istatistiksel analizlerle açık, anlaşılır ve bilimsel standartlara uygun bir şekilde sunulması.

- **Hedef 5: Model Yorumlanabilirliği ve Klinik Önem Analizi**

- Özellikle "kara kutu" olarak nitelendirilebilen derin öğrenme modelleri başta olmak üzere, en iyi performansı gösteren modelin veya modellerin karar verme süreçlerini anlamak ve hangi fizyolojik özniteliklerin tahminlerde ne ölçüde etkili olduğunu belirlemek için model yorumlanabilirliği tekniklerini (örneğin, SHAP (SHapley Additive exPlanations) ¹¹, LIME (Local Interpretable Model-agnostic Explanations) ¹⁸) uygulamak. SHAP yönteminin, makine öğrenmesi modellerinin sonuçlarını yorumlamak ve özelliklerin riskle olan ilişkisini (hem yönünü hem de büyüklüğünü) anlamaya yardımcı olduğu bilinmektedir.¹¹ SHAP ve LIME gibi tekniklerin, koroner kalp hastalığı (KKH) ve akut miyokard infarktüsü (AMI) hastalarının mortalite tahmin

modellerinde özellik katkılarını belirleyerek şeffaflığı artırdığı gösterilmiştir.¹⁸

- Kalp krizi riskiyle en güçlü ve anlamlı ilişkisi olan uykuyla ilişkili fizyolojik öznitelikleri (örneğin, belirli HRV parametreleri, SpO2 desatürasyon örüntüleri, spesifik uyku evresi değişiklikleri) ve bu özniteliklerin model tahminleri üzerindeki göreceli önemlerini belirlemek.
- Elde edilen bulguların potansiyel klinik anlamını, fizyolojik mekanizmalarla uyumunu ve gelecekteki klinik uygulamalara veya araştırmalara yönelik olası çıkarımlarını tartışmak.
- **Başarı Kriteri:** En iyi performansı gösteren modelin tahminlerinde en etkili olan ilk 10 (veya probleme uygun sayıda) fizyolojik özneliğin belirlenmesi ve bu özniteliklerin kalp krizi riski üzerindeki pozitif veya negatif katkılarının, SHAP değerleri gibi kantitatif ölçütlerle ve görselleştirmelerle (örneğin, SHAP özet grafikleri) desteklenerek açıkça yorumlanması.
- **Hedef 6: Proje Raporunun ve Sunumunun Hazırlanması**
 - Proje süresince gerçekleştirilen tüm adımları, kullanılan yöntemleri, elde edilen bulguları, yapılan analizleri ve varılan sonuçları detaylı bir şekilde açıklayan, bilimsel ve teknik standartlara uygun, kapsamlı bir proje raporu (tez veya bitirme projesi raporu formatında) yazmak.
 - Projenin amaçlarını, yöntemlerini, temel bulgularını ve katkılarını etkili bir şekilde özetleyen ve görsel materyallerle desteklenen bir sözlü sunum hazırlamak.
 - **Başarı Kriteri:** Verilen şablona ve akademik yönergelere tam olarak uygun, dilbilgisi ve yazım kuralları açısından hatasız, içerik olarak eksiksiz ve yüksek kalitede bir proje raporunun ve bu raporu destekleyen, açık ve etkili bir sunumun başarıyla tamamlanması ve teslim edilmesi.

Tablo 1, projenin SMART hedeflerini ve başarı kriterlerini özetlemektedir :

Tablo 1: SMART Hedefler ve Başarı Kriterleri

Hedef No.	Hedef Açıklaması	Ölçülebilirlik	Ulaşılabilirlik/Gerçekçilik	Zaman Sınırı	Başarı Kriteri
Hedef 1	Kapsamlı Literatür Taraması ve Veri Seti Belirleme	İncelenen makale sayısı (min. 20), temin edilen veri seti boyutu (min. 1 büyük ölçekli PSG veri seti, >1000 kayıt)	Mevcut bilimsel veritabanları ve PhysioNet gibi açık kaynaklar ile ulaşılabilir.	İlk 2 Ay	En az 20 ilgili makalenin incelenmesi ve en az bir büyük ölçekli PSG veri setinin temin edilmesi.
Hedef 2	Veri Ön İşleme ve Öznitelik Mühendisliği Süreci Geliştirme	Bu projede, en az 50 farklı öznitelik oluşturulacak ve bu öznitelikleri çıkarıp modeli eğiten bir otomatik analiz sistemi(pipeline) geliştirilecektir.	Python ve ilgili kütüphanelerle (Numpy, Scipy, MNE) gerçekleştirilebilir.	Ay 2-4	Temizlenmiş veri seti üzerinde, en az 50 farklı fizyolojik öznitelikten oluşan bir özellik matrisinin oluşturulması ve bu sürecin otomatikleştirilmiş bir analiz hattı (pipeline) ile yürütülmesi hedeflenmektedir.
Hedef 3	Yapay Zeka Modelleri Geliştirme ve Eğitim	Geliştirilen ve eğitilen YZ model sayısı (min. 3, en az biri DL), belgelenmiş eğitim süreci	Scikit-learn, TensorFlow/PyTorch gibi kütüphaneler ve mevcut donanım kaynakları ile	Ay 4-7	En az 3 farklı YZ modelinin (en az biri DL) geliştirilmesi, eğitilmesi ve hiperparametre optimizasyonunun yapılması. Eğitim sürecinin tekrarlanabilir

			mümkün.		ve belgelenmiş olması.
Hedef 4	Model Performansı nı Değerlendir me ve Karşılaştırm a	Hesaplanan performans metrikleri (Accuracy, Precision, Recall, F1, AUC), belirlenen eşiklerin karşılanması	Standart metrikler ve test veri seti kullanılarak objektif değerlendirme yapılabilir.	Ay 7-9	En iyi modelin test veri setinde önceden belirlenmiş performans eşiklerini (örn., AUC > 0.80, Duyarlılık > 0.75) karşılaması. Sonuçların tablo/grafiklerle sunulması.
Hedef 5	Model Yorumlanabil irliği ve Klinik Önem Analizi	Belirlenen en etkili öznitelik sayısı (ilk 10), yorumların kalitesi ve derinliği	SHAP, LIME gibi araçlarla ve literatür bilgisiyle gerçekleştirilebilir.	Ay 9-10	Modelin tahminlerinde en etkili ilk 10 öz niteliğin belirlenmesi ve bu öz niteliklerin risk üzerindeki etkilerinin (pozitif/negatif katkı) yorumlanması.
Hedef 6	Proje Raporunun ve Sunumunun Hazırlanma sı	Raporun ve sunumun tamamlanma durumu, kalite standartlarına uygunluğu	Proje süresince toplanan bilgi ve bulgularla yazılabilir.	Ay 10-12	Şablona uygun, eksiksiz ve yüksek kalitede bir proje raporunun ve etkili bir sunumun tamamlanması.

Bu hedeflerin yapılandırılması, projenin aşamalı ve mantıksal bir ilerleme kaydetmesini sağlamayı amaçlar. Örneğin, model yorumlanabilirliği (Hedef 5) sonuçları, ideal bir araştırma ortamında öznetelik mühendisliği (Hedef 2) veya model seçimi (Hedef 3) aşamalarına geri dönülerek iyileştirmeler yapılmasına olanak tanıyabilir; ancak, bir öğrenci projesinin zaman kısıtlamaları göz önüne alındığında, bu tür tam bir döngüsel yineleme yerine, her aşamadan elde edilen bilgilerin bir sonraki aşamayı en iyi şekilde bilgilendirmesi hedeflenir. Belirlenen AUC > 0.80 gibi performans ölçütleri, literatürdeki benzer çalışmalarda ulaşılan değerlere (örneğin, EKG'den tıkalı arterlerin saptanmasında AUC 0.91¹⁶ veya uyku HRV'si ile KVH sonuçları için %75.3 doğruluk¹⁰) dayanarak iddialı ancak ulaşılabilir bir başarı çitası belirlemektedir. Bu, projenin sadece bir mühendislik uygulaması olmanın ötesinde, bilimsel bir etki yaratma potansiyelini de göstermektedir.

4. YÖNTEM

Bu bölümde, projenin yukarıda belirtilen hedeflerine ulaşmak için izlenecek adımlar, kullanılacak teknolojiler, araçlar, algoritmalar, veri setleri ve genel yaklaşımlar detaylı bir şekilde açıklanmaktadır. Proje, sağlam bir bilimsel temele dayanan, metodolojik olarak titiz ve teknolojik olarak güncel bir yaklaşımla yürütülecektir.

- 4.1. Araştırma ve Literatür Taraması

Bu aşama, projenin temelini oluşturacak ve tüm sonraki adımlara yön verecektir.

Odaklanılacak anahtar alanlar şunlardır:

- **Uyku Fizyolojisi ve Bozuklukları:** Uyku evreleri (REM, NREM evreleri N1, N2, N3), uyku mimarisi, uyku düzenleyici mekanizmalar. Özellikle uyku apnesi, uykusuzluk (insomnia) ve uyku bölünmeleri (arousals) gibi yaygın uyku bozukluklarının prevalansı, tanı kriterleri ve fizyolojik etkileri detaylıca incelenecektir.¹
- **Kardiyovasküler Hastalıklar ve Kalp Krizi:** Akut miyokard infarktüsünün (AMI) patofizyolojisi, temel risk faktörleri (hipertansiyon, dislipidemi, diyabet, sigara kullanımı, obezite, aile öyküsü vb.), geleneksel tanı yöntemleri (EKG, kardiyak biyobelirteçler, anjiyografi) ve mevcut risk skorlama sistemleri (örn., Framingham Risk Skoru) araştırılacaktır.
- **Uyku-Kardiyovasküler İlişkisi:** Uyku kalitesi, süresi ve bozukluklarının kardiyovasküler sağlık üzerindeki etkilerini inceleyen epidemiyolojik, klinik ve deneysel çalışmalar taranacaktır. Bu ilişkinin altında yatan potansiyel mekanizmalar (sempatik sinir sistemi aktivasyonu, inflamasyon, oksidatif stres, endotel disfonksiyonu, metabolik sendrom vb.) anlaşılmasına çalışılacaktır.¹
- **Polisomnografi (PSG) Sinyal İşleme:** PSG sırasında kaydedilen temel fizyolojik sinyallerin (EEG, EOG, EMG, EKG, SpO2, solunum akışı ve eforu) özellikleri, bu sinyallerden anlamlı bilgilerin çıkarılması için kullanılan sinyal işleme teknikleri (filtreleme, artefakt tespiti, spektral analiz, dalgacık dönüşümü vb.) incelenecektir.⁸
- **Kalp Atım Hızı Değişkenliği (HRV) Analizi:** HRV'nin otonom sinir sisteminin

kardiyak fonksiyon üzerindeki modülasyonunu yansıtan non-invaziv bir gösterge olarak önemi, zaman ve frekans domeni HRV parametreleri, bu parametrelerin hesaplanma yöntemleri ve klinik anlamları araştırılacaktır.¹⁰

- **Kan Oksijen Satürasyonu (SpO2) Analizi:** SpO2 sinyalindeki desatürasyon örüntüleri, hipokseminin fizyolojik sonuçları ve özellikle uyku apnesi gibi durumlarda kardiyak etkileri incelenecektir.³
 - **Yapay Zeka Uygulamaları:** Makine öğrenmesi (ML) ve derin öğrenme (DL) algoritmalarının genel prensipleri, tıbbi veri analizi ve özellikle hastalık tahmini alanlarındaki uygulamaları, avantajları ve sınırlılıkları araştırılacaktır.⁴
 - **Mevcut Çalışmaların İncelenmesi:** Özellikle uyku verilerinden (PSG veya giyilebilir sensör verileri) kardiyovasküler risk (genel KVH riski, spesifik olaylar, aritmi, hipertansiyon vb.) tahmini yapan mevcut YZ tabanlı çalışmalar detaylı bir şekilde taranacaktır. Bu çalışmalarda kullanılan veri setleri, çıkarılan öznitelikler, uygulanan ML/DL modelleri, elde edilen performans metrikleri ve bildirilen sınırlılıklar not edilecektir. Bu kapsamlı tarama için IEEE Xplore, PubMed/MEDLINE, Google Scholar, ACM Digital Library, ArXiv gibi bilimsel veritabanları, ayrıca ilgili konferansların (örn., Computing in Cardiology - CinC, Sleep, American Thoracic Society - ATS) bildirileri kullanılacaktır. Bu taramanın temel çıktısı, projenin literatürdeki yerini, yenilikçi yönlerini ve mevcut çalışmalara potansiyel katkısını net bir şekilde ortaya koyan kapsamlı bir literatür özeti olacaktır. Bu özet, raporun "Literatür Taraması / Mevcut Çalışmalar" bölümünde daha detaylı sunulacaktır.
- 4.2. Veri Toplama ve Hazırlık

Bu aşama, projenin temelini oluşturan verilerin elde edilmesi ve analize uygun hale getirilmesini kapsar.

- **Veri Seti Seçimi:** Projenin başarısı için uygun veri setlerinin seçimi kritik öneme sahiptir. Öncelikli olarak, bilimsel araştırmalarda yaygın olarak kullanılan, büyük ölçekli, iyi belgelenmiş ve halka açık PSG veri setleri hedeflenecektir. Bu bağlamda PhysioNet platformu (physionet.org) birincil kaynak olacaktır. Potansiyel aday veri setleri şunlardır:
 - **Sleep Heart Health Study (SHHS):** Toplum tabanlı, çok merkezli bir kohort çalışması olup, 5000'den fazla katılımcıdan toplanmış tam gece PSG kayıtları ve uzun süreli takip verileri içermektedir.⁷ Özellikle kardiyovasküler sonlanım noktaları (kalp krizi, inme vb.) hakkında bilgi içermesi, bu projenin doğrudan kalp krizi riski tahmini hedefine hizmet etmesi açısından büyük bir avantajdır. SHHS veri seti, uyku HRV'si ile uzun vadeli KVH sonuçları arasındaki ilişkiyi inceleyen ve XGBoost modeli ile %75.3 doğruluk elde eden bir çalışmada başarıyla kullanılmıştır¹⁰, bu da veri setinin proje için uygunluğunu ve potansiyelini doğrulamaktadır.
 - **PhysioNet/Computing in Cardiology Challenge 2018 Veri Seti:** Yaklaşık 2000 katılımcıya ait, uyku arousallarının (uyanıklıklar, uyku bölünmeleri) uzmanlar tarafından etiketlendiği tam gece PSG kayıtlarını (EEG, EOG, EMG, EKG, SaO2

sinyalleri dahil) içermektedir.⁸ Uyku kalitesinin ve fragmentasyonunun kardiyovasküler riskle ilişkisi göz önüne alındığında, bu veri seti arousal örüntülerinin analizi için oldukça değerlidir.

- Diğer potansiyel veri setleri (örneğin, Multi-Ethnic Study of Atherosclerosis - MESA, MrOS Sleep Study, Apnea-ECG Database) literatür taraması sonucunda ve projenin spesifik ihtiyaçlarına göre değerlendirilecektir. Seçilecek veri setlerinin etik kurul onaylarının alınmış olması, verilerin uygun şekilde anonimleştirilmiş olması ve veri kullanım sözleşmelerinin (DUA) proje amaçlarıyla uyumlu olması temel kriterlerdir.
- **Sinyal Seçimi:** Projede, kalp krizi riskiyle ilişkili olabilecek fizyolojik bilgileri en iyi şekilde yansıttığı düşünülen temel PSG sinyalleri kullanılacaktır:
 - **EKG (Elektrokardiyogram):** Kalp atım hızı, ritim bozuklukları ve en önemlisi Kalp Atım Hızı Değişkenliği (HRV) analizi için temel sinyaldir.⁸
 - **SpO2 (Kan Oksijen Satürasyonu):** Gece boyunca yaşanan hipoksemi (oksijen düşüklüğü) ve desatürasyon olaylarının tespiti, özellikle uyku apnesi gibi durumların varlığı ve şiddeti hakkında bilgi verir.⁷
 - **EEG (Elektroensefalogram):** Beyin elektriksel aktivitesini yansıtarak uyku evrelerinin (W, N1, N2, N3, REM) belirlenmesi, beyin aktivitesi örüntülerinin analizi ve arousalların tespiti için kritik öneme sahiptir.⁸
 - **EOG (Elektrookülogram):** Göz hareketlerini kaydederek özellikle REM uykusunun tespiti ve arousalların doğrulanması için kullanılır.⁸
 - **EMG (Elektromiyogram):** Çene veya bacak kas aktivitesini ölçerek kas tonusu değişikliklerini, uyku evrelemesini (özellikle REM uykusundaki atoni) ve Periyodik Bacak Hareketleri (PLM) gibi motor olayları tespit etmek için kullanılır.⁸
 - **Solunum Sinyalleri (Nazal/oral hava akımı, göğüs ve karın hareketleri):** Apne (solunum durması) ve hipopne (solunum azalması) gibi solunum olaylarının tespiti ve solunum paternlerinin analizi için gereklidir.⁸
- **Veri Ön İşleme:** Ham PSG sinyalleri, analiz öncesinde çeşitli gürültü ve artefaktlardan arındırılmalıdır:
 - **Sinyal Filtreleme:** Güç hattı gürültüsünü (Türkiye için 50 Hz) gidermek için bant durduran (notch) filtreler; baz çizgisi kayması ve düşük frekanslı hareket artefaktlarını gidermek için yüksek geçiren filtreler; yüksek frekanslı gürültüleri azaltmak için alçak geçiren filtreler uygulanacaktır. Filtre türleri ve kesim frekansları, her bir sinyal tipinin özelliklerine ve literatürdeki standartlara göre belirlenecektir.
 - **Artefakt Tespiti ve Yönetimi:** Sinyal kalitesini ciddi şekilde bozan artefaktlı segmentler (örn., elektrotların yerinden oynaması, aşırı hareket) otomatik veya yarı otomatik yöntemlerle (örn., genlik eşikleme, sinyal varyansı analizi) tespit edilecek ve ya analizden çıkarılacak ya da bu segmentlerdeki özneliliklerin güvenilirliği düşük olarak işaretlenecektir.
 - **Normalizasyon/Standardizasyon:** Farklı kayıtlardan veya farklı sensörlerden

gelen sinyallerin genliklerini veya istatistiksel dağılımlarını karşılaştırılabilir hale getirmek için z-skoru normalizasyonu (ortalama 0, standart sapma 1) veya min-max ölçekleme gibi teknikler uygulanabilir.

- **Segmentasyon (Epoklama):** Sürekli PSG kayıtları, analiz türüne uygun uzunlukta epoklara bölünecektir. Örneğin, uyku evrelemesi için genellikle 30 saniyelik epoklar kullanılırken ⁸, HRV analizi için 2-5 dakikalık pencereler tercih edilebilir.¹⁰
- **Uyku Evrelemesi:** Eğer seçilen veri setinde uzmanlar tarafından yapılmış manuel uyku evresi skorları (Amerikan Uyku Tıbbi Akademisi - AASM standartlarına göre: W, N1, N2, N3, REM) mevcutsa, bu skorlar "altın standart" olarak kabul edilecek ve kullanılacaktır.⁸ Manuel skortlama yoksa veya mevcut skorların kalitesi şüpheliyse, literatürde kabul görmüş açık kaynaklı otomatik uyku evreleme araçları (örn., YASA - Yet Another Sleep Analyzer) veya bu proje kapsamında geliştirilecek basit bir CNN/RNN tabanlı uyku evreleme modeli kullanılabilir veya mevcut skorlar bu modellerle doğrulanabilir.⁹ Otomatik evreleme, özellikle büyük veri setlerinde tutarlılık ve verimlilik sağlar. Veri ön işleme ve hazırlık aşamalarında temel olarak Python programlama dili ve bu dile ait güçlü kütüphaneler olan Numpy (sayısal işlemler), Scipy (bilimsel hesaplamalar, sinyal işleme), Pandas (veri manipülasyonu), MNE-Python (EEG/MEG/EKG analizi), PyWavelets (dalgaçık analizi) ve YASA (uyku analizi) kullanılacaktır. Bu süreçlerin sonunda, her bir katılımcı için temizlenmiş, işlenmiş ve analize hazır sinyal verileri ve uyku evresi bilgileri elde edilecektir.

Aşağıdaki tablo, projede kullanılması hedeflenen potansiyel veri setlerinin temel özelliklerini özetlemektedir:

Tablo 2: Seçilen Veri Setlerinin Detayları (Örnek)

Veri Seti Adı	Kaynak	Katılımcı Sayısı (N)	Temel Demografik Bilgiler (Örnek)	Kaydedilen Temel PSG Sinyalleri	Etiket Bilgisi	Proje İçin Uygunluk Gerekçesi
SHHS (Visit 1 & 2)	PhysioNet	>5700 (Visit 1)	40-87 yaş, ~%50 Kadın	EKG, EEG (C3/A2, C4/A1), EOG (sol/sağ), EMG (çene), SpO2, Solunum	Uyku evreleri (uzman skorlaması), Solunum olayları, KVH sonlanım bilgisi	Büyük örneklem, uzun süreli takip, KVH sonlanım verisi varlığı, zengin PSG sinyalleri. Kalp krizi riskiyle doğrudan ilişkilendirilebilecek veriler içerir.
CinC Challenge 2018	PhysioNet	~1983	Çeşitli yaş ve cinsiyet	EKG, EEG (6 kanal), EOG (1 kanal), EMG (çene), SaO2, Hava Akışı	Uyku evreleri, Arousal etiketleri (uzman skorlaması)	Çok kanallı EEG, arousal etiketleri. Uyku kalitesi ve fragmentasyonunun detaylı analizi için uygun.
MESA (Multi-Ethnic Study of Atherosclerosis) Sleep	PhysioNet	>2000	45-84 yaş, çeşitli etnik kökenler	EKG, EEG, EOG, EMG, SpO2, Solunum, Aktigrafi	Uyku evreleri, Solunum olayları, KVH risk faktörleri ve subklinik hastalık belirteçleri	Etnik çeşitlilik, detaylı KVH risk faktörü verisi. Modelin farklı popülasyonlardaki geçerliliğini test etmek için potansiyel.

Tablo 2 , projenin veri temelini sađlamliđını ve seřilen veri kaynaklarının zenginliđini gřstermektedir. Veri setlerinin kapsamı, iřerdiđi sinyal ve etiket třrleri, projenin hedeflerine ulařmak iřin gerekli bilgileri sađlama potansiyelini vurgulamaktadır. zellikle SHHS gibi KVH sonlanım bilgilerini iřeren veri setleri, geliřtirilecek YZ modelinin dođrudan kalp krizi riskiyle iliřkilendirilmesine olanak tanıyacaktır.

- 4.3. znitelik ıkarımı ve Seřimi

Bu kritik ařamada, n iřlenmiř PSG sinyallerinden ve uyku evresi bilgilerinden, kalp krizi riskiyle potansiyel olarak iliřkili olduđu dřřnřlen kantitatif ve klinik olarak anlamlı znitelikler (features) ıkarılacaktır. Amaç, ham veriyi YZ modellerinin iřleyebileceđi ve anlamlı rřntřler ğrenebileceđi bir forma dnřřtřrmektir.

- **Kalp Atım Hızı Deđiřkenliđi (HRV) znitelikleri (EKG'den):** ¹⁰ HRV, otonom sinir sisteminin kalp řzerindeki etkisini yansıtır ve azalmıř HRV, artmıř kardiyovaskřler riskle gřçlř bir řekilde iliřkilidir.

- **Zaman Domeni znitelikleri:**

- SDNN (Normalden normale (NN) interval sřrelerinin standart sapması): Genel HRV'yi yansıtır.
- RMSSD (Ardıřık NN interval sřreleri arasındaki farkların karelerinin ortalamasının karekkř): Kısa sřreli, parasempatik etkileri yansıtır.
- pNN50 (Ardıřık NN interval sřreleri arasındaki farkın 50 ms'den břyřk olduđu interval sayısının toplam NN interval sayısına oranı): Parasempatik aktiviteyi gřsterir.
- NN50 (Ardıřık NN interval sřreleri arasındaki farkın 50 ms'den břyřk olduđu interval sayısı).
- SDANN (Genellikle 5 dakikalık segmentlerdeki ortalama NN intervallerinin standart sapması): Uzun sřreli HRV bileřenlerini yansıtır.
- SDNNI (Genellikle 5 dakikalık segmentlerdeki NN intervallerinin standart sapmalarının ortalaması).

- **Frekans Domeni znitelikleri (Lomb-Scargle periodogramı veya Hızlı Fourier Dnřřřmř (FFT) kullanılarak):**

- VLF (Very Low Frequency - ok Dřřřk Frekans) Gřcř (0.003-0.04 Hz): Uzun sřreli regřlasyon mekanizmalarıyla iliřkilidir.
- LF (Low Frequency - Dřřřk Frekans) Gřcř (0.04-0.15 Hz): Hem sempatik hem de parasempatik aktiviteyi yansıtabilir, barorefleks duyarlılıđıyla iliřkilidir.
- HF (High Frequency - Yřksek Frekans) Gřcř (0.15-0.4 Hz): Esas olarak parasempatik (vagal) aktiviteyi ve solunumla iliřkili HRV'yi (respiratory sinus arrhythmia) yansıtır. zellikle HF gřcřnřn KVH iřin bađımsız bir belirleyici olduđu ve normalize HF'nin KVH gecikmesiyle pozitif korelasyon gřsterdiđi belirtilmiřtir.¹⁰

- LF/HF Oranı: Sempatovagal dengeyi yansıttığı düşünülür, ancak yorumu dikkat gerektirir.
- Normalize LF ve HF Güçleri (LFnu, HFnu): $LFnu = LF / (\text{Toplam Güç} - VLF) * 100$; $HFnu = HF / (\text{Toplam Güç} - VLF) * 100$.
- Toplam Güç (TP): Belirli bir frekans aralığındaki (genellikle VLF+LF+HF) toplam varyans. Bu HRV öznitelikleri, tüm uyku periyodu için veya ayrı ayrı uyku evreleri (örneğin, NREM uykusu, REM uykusu, uyanıklık) için hesaplanarak uyku evresine özgü otonomik değişiklikler incelenebilir.
- **SpO2 Öznitelikleri (Oksimetre sinyalininden):** ³ Gece boyunca kan oksijen seviyesindeki dalgalanmalar, özellikle uyku apnesi varlığında, kardiyovasküler sistem üzerinde önemli bir stres kaynağıdır.
 - Ortalama SpO2, Minimum SpO2, SpO2'nin standart sapması.
 - Oksijen Desatürasyon İndeksi (ODI): Saat başına, SpO2'nin bazal seviyeden belirli bir yüzde (örn., %3 veya %4) veya daha fazla düştüğü olayların sayısı. ODI, uyku apnesi şiddetinin önemli bir göstergesidir.⁷
 - Belirli bir SpO2 eşiğinin (örn., <%90, <%88, <%85) altında geçirilen toplam süre veya uyku süresine oranı (T90, T88, T85).
 - Desatürasyon olaylarının ortalama ve maksimum süresi, ortalama ve minimum SpO2 düşüş miktarı (derinliği), desatürasyon ve resatürasyon eğimleri gibi morfolojik özellikler.
 - SpO2 sinyalinin entropi veya karmaşıklık ölçümleri.
- **Solunum Öznitelikleri (Hava akımı ve solunum eforu sinyallerinden):**
 - Apne-Hipopne İndeksi (AHI): Saat başına yaşanan apne (solunum durması) ve hipopne (solunumda belirgin azalma) olaylarının sayısı. Veri setinde etiketlenmemişse, standart AASM kurallarına dayalı otomatik tespit algoritmaları kullanılabilir.
 - Apne ve hipopne olaylarının ortalama ve maksimum süresi, tipleri (obstrüktif, santral, mikst).
 - Solunum hızı ve solunum hızı değişkenliği.
 - Cheyne-Stokes solunumu gibi periyodik solunum örüntülerinin varlığı ve süresi.
- **Uyku Mimarisi ve Kalitesi Öznitelikleri (EEG, EOG, EMG ve uyku evresi skorlarından):** Uyku yapısındaki bozulmalar genel sağlık ve kardiyovasküler fonksiyonlar üzerinde etkilidir.
 - Toplam Uyku Süresi (TST), Yatakta Geçirilen Süre (TIB), Uyku Verimliliği ($SE = TST/TIB * 100$).
 - Her bir uyku evresinde (W-Uyanıklık, N1, N2, N3-Derin Uyku, REM-Rüya Uykusu) geçirilen mutlak süre ve TST'ye oranı (yüzdesi).
 - Uykuya Dalma Latansı (SOL: ışıkların kapanmasından ilk uyku evresine geçiş süresi).
 - REM Uykusu Latansı (uyku başlangıcından ilk REM evresine geçiş süresi).
 - Uyanıklık Sonrası Uyku Başlangıcı (WASO: uykuya daldıktan sonra gece boyunca

uyanık kalınan toplam süre).

- Arousal İndeksi: Saat başına yaşanan kortikal arousal (uyanıklık benzeri kısa süreli beyin aktivasyonu) sayısı. Uyku bölünmesinin önemli bir göstergesidir.⁸
- Uyku evreleri arası geçişlerin sayısı ve örüntüleri.
- **EEG Spektral Öznitelikleri:** Farklı uyku evrelerinde veya tüm gece boyunca EEG sinyalinin farklı frekans bantlarındaki (Delta: 0.5-4 Hz, Teta: 4-8 Hz, Alfa: 8-13 Hz, Sigma/Uyku İğcikleri: 12-15 Hz, Beta: 13-30 Hz) mutlak ve göreceli güçleri. Bu öznitelikler, uyku derinliği ve kalitesi hakkında bilgi verebilir.
- **Diğer Potansiyel Öznitelikler:**
 - Periyodik Bacak Hareketleri (PLM) İndeksi (EMG bacak kanallarından).
 - EKG'den türetilmiş solunum (EDR - ECG-Derived Respiration) teknikleri ile elde edilen solunum bilgileri (eğer doğrudan solunum sinyalleri yetersizse).
 - Katılımcının demografik bilgileri (yaş, cinsiyet), antropometrik ölçümleri (Vücut Kitle İndeksi - VKİ) ve temel klinik bilgileri (hipertansiyon varlığı, diyabet öyküsü, sigara kullanımı durumu vb.) – eğer veri setinde mevcutsa ve etik kurallar çerçevesinde kullanılabilirse, bu bilgiler modele dahil edilebilir.
- **Öznitelik Seçimi:** Çıkarılan öznitelik sayısı çok fazla olabilir (yüksek boyutluluk problemi) ve bu durum modelin karmaşıklığını artırabilir, aşırı öğrenmeye yol açabilir ve yorumlanabilirliği zorlaştırabilir. Bu nedenle, en bilgilendirici ve kalp krizi riskiyle en ilişkili alt kümeyi belirlemek için öznitelik seçimi teknikleri uygulanacaktır. Bu teknikler, gereksiz (redundant) ve ilişkisiz (irrelevant) öznitelikleri eleterek model performansını artırmayı ve eğitim süresini kısaltmayı hedefler. Çeşitli öznitelik seçimi tekniklerinin KVH tahmininde Adaboost ve Karar Ağacı (DT) modellerinin performansını önemli ölçüde artırdığı (örneğin, Adaboost doğruluğunun MRMR ile %74'ten %88'e çıktığı) ve eğitim süresini kısalttığı gösterilmiştir.²⁶
 - **Filtre Yöntemleri:** Özniteliklerin istatistiksel özelliklerine göre (modelden bağımsız olarak) sıralandığı veya seçildiği yöntemlerdir. Örnekler: Karşılıklı Bilgi (Mutual Information), ANOVA F-testi (sürekli öznitelik, kategorik hedef için), Ki-kare testi (kategorik öznitelik, kategorik hedef için), varyans eşikleme.
 - **Sarmalayıcı (Wrapper) Yöntemler:** Belirli bir makine öğrenmesi modelini kullanarak öznitelik alt kümelerinin performansını değerlendiren ve en iyi alt kümeyi arayan yöntemlerdir. Örnekler: Özyinelemeli Öznitelik Eleme (Recursive Feature Elimination - RFE) ²⁶, İleriye Doğru Seçim (Forward Selection), Geriye Doğru Eleme (Backward Elimination).
 - **Gömülü (Embedded) Yöntemler:** Öznitelik seçimi sürecini modelin eğitim süreciyle bütünleştiren yöntemlerdir. Örnekler: LASSO (L1 regülerizasyonu) kullanan regresyon modelleri, ağaç tabanlı modellerin (Random Forest, XGBoost, LightGBM) sunduğu öznitelik önem skorları (feature importance scores).
 - **Gelişmiş Yöntemler:** Maksimum Alaka Düzeyi Minimum Gereksizlik (Maximum Relevance Minimum Redundancy - MRMR) ²⁶, Boruta algoritması ²⁶ gibi daha sofistike yaklaşımlar da denenebilir. MRMR, hedef değişkenle yüksek korelasyona

sahip ancak kendi aralarında düşük korelasyona sahip öznitelikleri seçmeyi amaçlar. Boruta, rastgele gölge öznitelikler oluşturarak gerçek özniteliklerin önemini istatistiksel olarak test eder. Öznitelik çıkarımı ve seçimi için Python ve Scikit-learn kütüphanesinin feature_selection modülü, ayrıca BorutaPy, mrmr_selection gibi özel paketler kullanılacaktır. Bu aşamanın sonunda, her bir katılımcı için optimize edilmiş bir öznitelik vektörü oluşturulmuş olacaktır.

- 4.4. Yapay Zeka Modeli Geliştirme ve Eğitimi

Bu aşamada, önceki adımlarda hazırlanan öznitelik setleri kullanılarak kalp krizi riskini tahmin edecek yapay zeka modelleri geliştirilecek ve eğitilecektir. Hem geleneksel makine öğrenmesi (ML) hem de derin öğrenme (DL) yaklaşımları, performanslarını ve özelliklerini karşılaştırmak amacıyla denenecektir. Bu ikili yaklaşım, "her probleme uyan tek bir en iyi algoritma yoktur" (No Free Lunch teoremi) prensibini yansıtır; farklı modeller farklı veri yapıları ve karmaşıklık seviyeleri için daha uygun olabilir.

- **Makine Öğrenmesi (ML) Modelleri:** ¹⁰ Bu modeller genellikle mühendislik ürünü (elle çıkarılmış) özniteliklerle iyi çalışır ve bazıları yüksek yorumlanabilirlik sunar.

- **Lojistik Regresyon (LR):** Basit, hızlı eğitilebilen ve sonuçları kolay yorumlanabilen doğrusal bir modeldir. Genellikle başlangıç (baseline) modeli olarak kullanılır.
- **Destek Vektör Makineleri (SVM):** Yüksek boyutlu öznitelik uzaylarında etkili olan, doğrusal veya farklı çekirdek fonksiyonları (kernel tricks - örn., RBF, polinom) kullanarak doğrusal olmayan karar sınırları oluşturabilen güçlü bir sınıflandırıcıdır.
- **Rastgele Orman (Random Forest - RF):** Birden fazla karar ağacının tahminlerini birleştirerek çalışan bir topluluk öğrenme yöntemidir. Aşırı öğrenmeye (overfitting) karşı daha dirençlidir ve öznitelik önem skorları üretebilir.
- **Gradyan Artırma Makineleri (Gradient Boosting Machines - GBM):** XGBoost, LightGBM veya CatBoost gibi uygulamalarıyla bilinir. Zayıf öğrencileri (genellikle karar ağaçları) sıralı bir şekilde ekleyerek ve her yeni öğrencinin önceki öğrencilerin hatalarını düzeltmeye odaklanmasını sağlayarak çok yüksek tahmin performansı elde edebilirler. XGBoost'un uyku HRV'si ile KVH tahmini için kullanıldığı ve %75.3 doğruluk sağladığı bir çalışma ¹⁰, GBM'in ise OSA-ilişkili hipertansiyon tahmininde %88.5 doğruluk ve %0.873 AUC ile en iyi performansı gösterdiği başka bir çalışma ¹¹ bu tür algoritmaların potansiyelini vurgulamaktadır.

- **Derin Öğrenme (DL) Modelleri:** ¹² Bu modeller, özellikle ham veya daha az işlenmiş zaman serisi verilerinden hiyerarşik ve karmaşık örüntüleri otomatik olarak öğrenebilme yetenekleriyle öne çıkarlar. Ancak genellikle daha fazla veri ve hesaplama gücü gerektirirler.

- **Evrişimli Sinir Ağları (CNN):** Özellikle EKG, EEG gibi fizyolojik sinyallerdeki yerel örüntüleri, şekilleri ve frekans bileşenlerini yakalamada etkilidir. ¹³ Zaman serisi verileri için genellikle 1D CNN'ler kullanılır. Bu modeller, sinyaldeki invaryant özellikleri (zamanda kaymaya veya küçük deformasyonlara duyarız)

öğrenmeye yardımcı olabilir.

- **Tekrarlayan Sinir Ağları (RNN) / Uzun Kısa Süreli Bellek (LSTM) / Geçitli Tekrarlayan Birim (GRU):** Zaman serisi verilerindeki zamansal bağımlılıkları ve sıralı bilgiyi modellemede güçlüdürler. Uyku verilerinin (örneğin, uyku evrelerinin sıralı geçişleri, HRV veya SpO2 trendleri) doğası gereği bu mimariler uygundur.¹² LSTM ve GRU'lar, geleneksel RNN'lerdeki "vanishing/exploding gradient" sorunlarının üstesinden gelmek için tasarlanmıştır.
- **CNN-LSTM Hibrit Modelleri:** CNN katmanları ile sinyallerden yerel ve uzamsal (veya spektral) özniteliklerin çıkarılmasını, ardından LSTM katmanları ile bu özniteliklerin zamansal dinamiklerinin modellenmesini birleştirerek her iki mimarinin avantajlarından yararlanmayı hedefler.
- **Transformer Modelleri:** Doğal dil işlemede devrim yaratan bu mimariler, dikkat mekanizmaları (attention mechanisms) sayesinde özellikle uzun vadeli bağımlılıkları yakalamada ve farklı sinyal modaliteleri veya zaman serisi segmentleri arasındaki ilişkileri öğrenmede umut vericidir.¹² Uyku verileri gibi uzun ve çok kanallı zaman serileri için potansiyel taşırlar. Nitekim, çok modlu (PPG, solunum) verilerle uyku evreleri ve uyku apnesi sınıflandırması için 1D-Vision Transformer öneren çalışmalar bulunmaktadır.²⁰ Ayrıca, CNN ve Transformer mimarilerini birleştiren hibrit modellerin, yaşam öyküsü verilerinden (uyku kalitesi dahil) kalp hastalığı riskini tespit etmede geleneksel ML ve saf DL modellerinden daha iyi performans gösterdiği rapor edilmiştir¹⁴, bu da projedeki hibrit DL yaklaşımlarının araştırılması için güçlü bir motivasyon sağlamaktadır. Derin öğrenme modellerinin ham zaman serisi verilerinden karmaşık zamansal özellikleri otomatik olarak öğrenebilmesi¹², öznitelik mühendisliği yükünü azaltma potansiyeli sunar, ancak iyi tasarlanmış öznitelikler bu modellerin performansını daha da artırabilir.
- **Eğitim Süreci:**
 - **Veri Bölme:** Veri seti, modelin genelleme performansının güvenilir bir şekilde değerlendirilmesi için tipik olarak %70 eğitim (training), %15 doğrulama (validation) ve %15 test (testing) olarak bölünecektir. Veri sızıntısını (data leakage) önlemek amacıyla, bu bölme işlemi katılımcı (subject) düzeyinde yapılacaktır; yani aynı katılımcıya ait veriler farklı alt kümelerde (eğitim, doğrulama, test) yer almayacaktır.
 - **Çapraz Doğrulama (Cross-Validation):** Modelin genelleme performansını daha kararlı bir şekilde tahmin etmek, aşırı öğrenmeyi tespit etmek ve hiperparametre optimizasyonunu daha güvenilir yapmak için eğitim seti üzerinde k-katmanlı (örn., 5 veya 10 katmanlı) çapraz doğrulama uygulanacaktır.
 - **Kayıp Fonksiyonu (Loss Function):** Bu bir ikili sınıflandırma problemi (yüksek riskli / düşük riskli) olduğundan, uygun bir kayıp fonksiyonu olarak ikili çapraz entropi (binary cross-entropy) veya odaklanmış kayıp (focal loss - dengesiz sınıflar için) seçilecektir.

- **Optimizasyon Algoritması:** Derin öğrenme modelleri için Adam, AdamW, RMSprop veya SGD (Stokastik Gradyan İnişi) gibi modern optimizasyon algoritmaları kullanılacaktır.
- **Hiperparametre Optimizasyonu:** Modellerin performansını en üst düzeye çıkarmak için kritik hiperparametreleri (örn., öğrenme oranı, ağaç sayısı/derinliği, katman sayısı, nöron sayısı, regülarizasyon katsayıları, dropout oranı vb.) doğrulama seti üzerinde sistematik olarak optimize etmek amacıyla Grid Search, Random Search veya daha gelişmiş teknikler olan Bayesian Optimizasyon (örn., Optuna, Hyperopt kütüphaneleri ile) kullanılacaktır.
- **Aşırı Öğrenmeyi (Overfitting) Önleme Teknikleri:** Derin öğrenme modellerinin karmaşıklığı göz önüne alındığında, aşırı öğrenme önemli bir risktir. Bunu azaltmak için çeşitli teknikler uygulanacaktır: Erken durdurma (early stopping - doğrulama seti üzerindeki performans düşmeye başladığında eğitimi durdurma), Dropout (eğitim sırasında rastgele nöronları devre dışı bırakma), L1/L2 regülarizasyonu (ağırlıkların büyüklüğünü cezalandırma), Veri artırma (data augmentation - eğer zaman serisi verileri için uygun ve anlamlıysa, örn., gürültü ekleme, zamanla kaydırma).
- **Kullanılacak Araçlar ve Kütüphaneler:** Tüm model geliştirme ve eğitim süreçleri için Python programlama dili kullanılacaktır. Makine öğrenmesi modelleri için Scikit-learn; derin öğrenme modelleri için TensorFlow (Keras API ile) veya PyTorch gibi popüler ve güçlü kütüphaneler tercih edilecektir. Hiperparametre optimizasyonu için Optuna veya Hyperopt gibi kütüphanelerden yararlanılacaktır.
- **Donanım İhtiyacı:** Özellikle derin öğrenme modellerinin (özellikle Transformer gibi karmaşık mimarilerin ve SHHS gibi büyük veri setlerinin) eğitimi, önemli miktarda hesaplama gücü gerektirir. Bu nedenle, eğitim süreçlerini hızlandırmak ve proje takvimine uymak için GPU (Grafik İşlem Birimi) hızlandırmalı bir sistem (örn., NVIDIA GPU'lu bir yerel iş istasyonu veya Google Colab Pro, AWS EC2 P3 örnekleri, Azure ML gibi bulut tabanlı GPU hizmetleri) kritik bir gereklilik olacaktır. Bu kaynak ihtiyacı, projenin "Gerekli Kaynaklar" bölümünde detaylandırılacaktır.

Tablo 3, projede denenmesi planlanan aday yapay zeka modellerini, temel özelliklerini ve literatürdeki desteklerini özetlemektedir:

Tablo 3: Aday Yapay Zeka Modelleri ve Özellikleri

Model Adı	Model Türü	Temel Avantajları	Potansiyel Dezavantajları/Zorlukları	Uyku Verileriyle İlgili Literatür Desteği (Örnek)	Projede Kullanım Gerekçesi
Lojistik Regresyon	Doğrusal Model	Basit, hızlı, yorumlanabilir, iyi bir başlangıç noktası.	Karmaşık, doğrusal olmayan ilişkileri yakalayamaz.	-	Temel (baseline) model olarak performans karşılaştırması için.
SVM	Çekirdek Tabanlı Sınıflandırıcı	Yüksek boyutlu uzaylarda etkili, doğrusal olmayan karar sınırları oluşturabilir.	Büyük veri setlerinde yavaş olabilir, hiperparametre seçimi hassastır.	¹³ (uyku apnesi için)	Doğrusal olmayan örüntüleri yakalama potansiyeli için.
Random Forest	Topluluk Öğrenme (Karar Ağaçları)	Aşırı öğrenmeye dirençli, öznitelik önemi sunar, farklı veri türleriyle iyi çalışır.	Çok sayıda ağaç gerektiğinde yavaş olabilir, "kara kutu" özelliği olabilir.	¹³ (uyku apnesi için) ²⁶ (KVH için)	Güçlü performansı ve öznitelik önemi sağlama yeteneği için.

XGBoost/LightGBM	Gradyan Artırma (Karar Ağaçları)	Genellikle en yüksek performansı veren ML algoritmalarında n, aşırı öğrenmeyi iyi yönetir, paralel işleme.	Çok sayıda hiperparametresi vardır, ayarlanması zaman alabilir.	¹⁰ (KVH için) ¹¹ (hipertansiyon için)	Literatürde KVH ve uykuyla ilişkili problemlerde kanıtlanmış yüksek performansı için.
1D-CNN	Evrişimli Sinir Ağı	Fizyolojik sinyallerdeki yerel örüntüleri ve şekilleri otomatik olarak öğrenir, öznel mükemmeliyet yükünü azaltır.	Büyük veri ve GPU gerektirir, yorumlanması zor olabilir.	¹³	EKG, EEG, SpO2 gibi zaman serisi sinyallerinden doğrudan özellik çıkarımı için.
LSTM/GRU	Tekrarlayan Sinir Ağı	Zaman serisi verilerindeki uzun süreli zamansal bağımlılıkları modelleyebilir.	Eğitimleri yavaş olabilir, "vanishing/exploding gradient" sorunlarına hassas olabilir (GRU/LSTM ile azalır).	¹²	Uyku evreleri dizileri, HRV/SpO2 trendleri gibi sıralı verilerdeki dinamikleri yakalamak için.

CNN-LSTM Hibrit	Hibrit Derin Öğrenme	CNN ile yerel özellik çıkarımı, LSTM ile zamansal modelleme; her ikisinin avantajlarını birleştirir.	Mimarisi karmaşık olabilir, ayarlanması zor olabilir.	- (Genel DL prensibi)	Hem sinyallerdeki anlık örüntüleri hem de bu örüntülerin zaman içindeki değişimini modellemek için.
Transformer	Dikkat Mekanizması Tabanlı Derin Öğrenme	Uzun vadeli bağımlılıkları çok iyi yakalar, paralel işlenebilir, çok modlu veriler için umut verici.	Çok büyük veri ve hesaplama gücü gerektirir, uyku verilerine uyarlanması araştırma konusudur.	¹²	Özellikle çok kanallı PSG verilerindeki karmaşık ve uzun süreli ilişkileri, farklı sinyal modaliteleri arasındaki etkileşimleri (cross-modal attention) yakalama potansiyeli için.
CNN-Transformer Hibrit	Hibrit Derin Öğrenme	CNN ile etkili yerel özellik çıkarımı, Transformer ile güçlü global ve zamansal ilişki modellemesi.	Oldukça karmaşık mimari, yüksek hesaplama maliyeti.	¹⁴ (kalp hastalığı için)	Kalp hastalığı tahmininde umut verici sonuçlar verdiği için, PSG verilerindeki hem lokal hem de global örüntüleri en üst düzeyde yakalama potansiyeli için.

Tablo 3, model seçim stratejisinin çeşitliliğini ve her bir modelin projeye potansiyel katkısını göstermektedir. Literatürdeki kanıtlar ve modellerin teorik avantajları, bu seçimlerin rastgele olmadığını, aksine projenin hedeflerine ulaşmak için bilinçli bir stratejinin parçası olduğunu ortaya koymaktadır.

- 4.5. Model Değerlendirme ve Doğrulama

Eğitilmiş modellerin gerçek dünya performansını ve genelleme yeteneğini ölçmek için titiz bir değerlendirme ve doğrulama süreci izlenecektir. Bu süreç, modelin sadece eğitim verilerine aşırı uyum sağlamadığından (overfitting) emin olmak ve farklı modeller arasında adil bir karşılaştırma yapmak için kritik öneme sahiptir.

- **Test Veri Seti Üzerinde Değerlendirme:** Modellerin nihai performansı, eğitim ve doğrulama (hiperparametre optimizasyonu) aşamalarında kesinlikle kullanılmamış olan, tamamen ayrı bir **test veri seti** üzerinde değerlendirilecektir. Bu, modelin daha önce hiç görmediği verilere ne kadar iyi genelleme yapabildiğinin en objektif ölçüsüdür.
- **Temel Performans Metrikleri:** ¹⁰ Sınıflandırma probleminin doğası (ikili sınıflandırma: yüksek risk / düşük risk) ve potansiyel sınıf dengesizliği (kalp krizi riski taşıyan bireylerin genel popülasyonda azınlıkta olması muhtemeldir) göz önüne alınarak çeşitli performans metrikleri kullanılacaktır:
 - **Doğruluk (Accuracy):** Doğru sınıflandırılan örneklerin (TP+TN) toplam örnekler oranı $((TP+TN) / (TP+TN+FP+FN))$. Sınıflar dengesiz olduğunda yanıltıcı olabilir.
 - **Kesinlik (Precision) veya Pozitif Öngörü Değeri (PPV):** Pozitif olarak tahmin edilen örnekler arasında gerçekten pozitif olanların oranı $(TP / (TP+FP))$. Yüksek riskli olarak tahmin edilen bir bireyin gerçekten yüksek riskli olma olasılığını gösterir.
 - **Duyarlılık (Recall/Sensitivity) veya Gerçek Pozitif Oranı (TPR):** Gerçekten pozitif olan örnekler arasında doğru bir şekilde pozitif olarak tahmin edilenlerin oranı $(TP / (TP+FN))$. Yüksek riskli bireyleri kaçırmama yeteneğini ölçer; bu, erken teşhis için kritik bir metriktir.
 - **Özgüllük (Specificity) veya Gerçek Negatif Oranı (TNR):** Gerçekten negatif olan örnekler arasında doğru bir şekilde negatif olarak tahmin edilenlerin oranı $(TN / (TN+FP))$. Düşük riskli bireyleri doğru tanımlama yeteneğini ölçer.
 - **F1-Skoru:** Kesinlik ve duyarlılığın harmonik ortalaması $(2 * (Precision * Recall) / (Precision + Recall))$. Özellikle sınıf dengesizliği durumunda doğruluğa göre daha iyi bir ölçüttür.
 - **ROC Eğrisi Altındaki Alan (AUC-ROC):** Modelin farklı sınıflandırma eşik değerlerindeki performansını özetleyen, genel ayırt etme gücünün bir ölçüsüdür. 1'e ne kadar yakınsa, model o kadar iyidir. 0.5 rastgele tahmini gösterir. Özellikle dengesiz veri setlerinde ve farklı modelleri karşılaştırırken yaygın olarak kullanılır. Hedeflenen AUC değerinin 0.80-0.85 aralığında veya daha yüksek olması amaçlanmaktadır. Bir YZ modelinin EKG'den tıkalı koroner arterleri saptamada AUC 0.91 (iç test) ve 0.85 (dış validasyon) gibi değerlere ulaştığı bildirilmiştir ¹⁶,

bu da projenin hedeflerinin iddialı ama ulaşılabilir olduğunu göstermektedir.

- **Precision-Recall Eğrisi Altındaki Alan (AUC-PR):** Özellikle pozitif sınıfın (yüksek riskli bireyler) azınlıkta olduğu durumlarda, ROC AUC'den daha bilgilendirici olabilir ve modelin pozitif sınıfı ne kadar iyi tanımladığını gösterir.
- **Cohen's Kappa:** Sınıflandırıcının rastgele bir şansla elde edilecek doğruluğa göre ne kadar daha iyi performans gösterdiğini ölçer. Uyku evrelemesi gibi alanlarda kullanıldığı görülmektedir.⁹
- **Modellerin Karşılaştırılması:** Geliştirilen tüm farklı modellerin (geleneksel ML modelleri, farklı DL mimarileri) performansları, yukarıda listelenen metrikler kullanılarak test veri seti üzerinde karşılaştırılacak ve projenin hedeflerine en uygun, en iyi performansı veren model (veya modeller) belirlenecektir.
- **İstatistiksel Anlamlılık Testleri:** Gerekirse, farklı modeller arasındaki performans farklarının (örneğin, AUC değerleri arasındaki fark) istatistiksel olarak anlamlı olup olmadığını değerlendirmek için uygun istatistiksel testler (örn., McNemar testi, DeLong testi ROC AUC karşılaştırması için) kullanılabilir.
- **Hata Analizi (Error Analysis):** Modelin sadece genel performansına bakmak yerine, yanlış sınıflandırdığı örneklerle (Yanlış Pozitifler - FP: düşük riskli olmasına rağmen yüksek riskli olarak tahmin edilenler; Yanlış Negatifler - FN: yüksek riskli olmasına rağmen düşük riskli olarak tahmin edilenler) daha yakından bakılacaktır. Bu örneklerin özellikleri incelenerek modelin hangi durumlarda veya hangi tür katılımcılarda zorlandığı, zayıf yönleri ve potansiyel iyileştirme alanları belirlenmeye çalışılacaktır. Özellikle Yanlış Negatifler, erken teşhis amacına ters düştüğü için klinik açıdan daha kritik olabilir.
- **Dış Doğrulama (External Validation - İsteğe Bağlı/Gelecek Çalışma):** İdeal olarak, modelin genelleştirilebilirliğini tam olarak test etmek için, eğitimde kullanılan veri setinden tamamen farklı bir kaynaktan (farklı hastane, farklı coğrafi bölge, farklı cihazlar) gelen bir dış doğrulama veri seti üzerinde de test edilmesi gerekir. Bu, projenin mevcut kapsamı ve zaman kısıtlamaları dahilinde mümkün olmayabilir ancak gelecek çalışmalar için önemli bir adım olarak not edilecektir. ¹⁶te belirtildiği gibi, model performansı genellikle dış doğrulama kohortunda bir miktar düşüş gösterir. Bu kapsamlı değerlendirme süreci, geliştirilen modelin sadece teorik olarak değil, pratik olarak da ne kadar güvenilir ve etkili olduğunu anlamamızı sağlayacaktır.
- **4.6. Model Yorumlanabilirliği (Interpretability)**

Özellikle derin öğrenme modelleri gibi karmaşık "kara kutu" (black-box) algoritmaların tahmin performansları yüksek olsa da, karar verme süreçlerinin anlaşılması zordur. Tıbbi uygulamalarda, bir modelin neden belirli bir tahminde bulunduğunu anlamak, hem klinik güven ve kabul için hem de modelin hatalarını veya potansiyel yanlılıklarını tespit etmek için kritik öneme sahiptir.⁴ Bu nedenle, proje kapsamında en iyi performansı gösteren modelin (veya modellerin) yorumlanabilirliği üzerine özel bir odaklanma olacaktır.

 - **Kullanılacak Teknikler:**
 - **SHAP (SHapley Additive exPlanations):** Oyun teorisinden esinlenen bu yöntem,

her bir özniteliğin modelin belirli bir tahmini (lokal yorumlanabilirlik) veya genel model davranışı (global yorumlanabilirlik) üzerindeki katkısını adil bir şekilde hesaplar. SHAP değerleri, bir özniteliğin bir tahmini ne kadar artırdığını veya azalttığını gösterir ve bu sayede hangi özniteliklerin model kararlarında en etkili olduğu anlaşılabilir.¹¹ SHAP'ın, makine öğrenmesi modellerinin sonuçlarını yorumlamak ve özelliklerin riskle ilişkisini (hem yönünü hem de büyüklüğünü) anlamaya yardımcı olduğu¹¹ ve KKH tahmin modellerinde özellik katkılarını belirleyerek şeffaflığı artırdığı gösterilmiştir.¹⁸ Bu analizler, örneğin EKG/HRV temelli özniteliklerin (ST eğimi, göğüs ağrısı tipi gibi) önemini vurgulayabilir¹⁸, ki bu da projenin benzer özniteliklerin rolünü araştırması gerektiğini düşündürür.

- **LIME (Local Interpretable Model-agnostic Explanations):** Herhangi bir kara kutu modelin belirli bir örneğe yaptığı tahminin etrafında, yerel olarak yorumlanabilir bir vekil model (surrogate model - genellikle doğrusal bir model veya karar ağacı) eğiterek karmaşık modelin o bölgedeki davranışını açıklar.¹⁸ LIME, özellikle tek bir hastanın risk skorunun neden yüksek veya düşük olduğunu anlamak için faydalı olabilir.
- **Öznitelik Önem Skorları (Feature Importance Scores):** Ağaç tabanlı modeller (Random Forest, XGBoost, LightGBM gibi) eğitim sırasında doğal olarak her bir özniteliğin modelin karar verme sürecine ne kadar katkıda bulunduğunu gösteren önem skorları üretir. Bu skorlar, modelin hangi özniteliklere daha fazla odaklandığını anlamak için bir başlangıç noktası sunar.
- **Permütasyon Önemi (Permutation Importance):** Model eğitildikten sonra, bir özniteliğin değerleri test veri setinde rastgele karıştırılır (permute edilir) ve modelin performansındaki (örn., AUC veya doğruluk) düşüş ölçülür. Performansta büyük bir düşüşe neden olan öznitelikler daha önemli kabul edilir. Bu yöntem model-agnostiktir (herhangi bir modele uygulanabilir).
- **Dikkat Mekanizmalarının Görselleştirilmesi (Transformer modelleri için):** Eğer Transformer tabanlı modeller kullanılırsa, dikkat ağırlıkları (attention weights) görselleştirilerek modelin sinyalin veya özniteliklerin hangi kısımlarına daha fazla odaklandığı anlaşılabilir.

○ **Elde Edilecek Çıktılar ve Amaçlar:**

- Kalp krizi riski tahmininde en etkili olan uykuya ilişkili fizyolojik özniteliklerin bir sıralamasının ve göreceli önemlerinin belirlenmesi.
- Bu önemli özniteliklerin risk üzerindeki etki yönünün (riski artırıcı mı azaltıcı mı olduğu) ve bu etkinin büyüklüğünün (SHAP değerleri gibi) kantitatif olarak gösterilmesi.
- Modelin karar verme mantığını daha anlaşılır kılmak için çeşitli görselleştirmeler (örn., SHAP özet grafikleri (summary plots), bağımlılık grafikleri (dependency plots), kuvvet grafikleri (force plots), LIME açıklamaları) oluşturulması.
- Bu analizler, modelin sadece istatistiksel korelasyonları değil, aynı zamanda klinik olarak anlamlı ve fizyolojik olarak makul örüntüleri öğrendiğini doğrulamaya

yardımcı olacaktır. Eğer model, literatürle veya klinik sezgiyle çelişen beklenmedik özniteliklere dayanıyorsa, bu durum daha fazla araştırma veya modelde iyileştirme gerektirebilir.

- Yorumlanabilirlik, modelin potansiyel yanlılıklarını (bias) ortaya çıkarmada da rol oynayabilir. Örneğin, model belirli bir demografik gruba ait özniteliklere aşırı ağırlık veriyorsa, bu durum adalet sorunlarına işaret edebilir. Bu yorumlanabilirlik çabaları, geliştirilen YZ modelinin sadece bir "tahmin makinesi" olmasının ötesine geçerek, uyku ve kalp sağlığı arasındaki ilişkiye dair yeni bilimsel anlayışlar sunma potansiyelini artıracaktır.

● 4.7. Proje Yönetimi

Projenin başarılı bir şekilde tamamlanması, hedeflerine ulaşması ve zamanında bitirilmesi için etkili bir proje yönetimi yaklaşımı benimsenecektir.

- **Metodoloji:** Proje, doğası gereği araştırma ve geliştirme (Ar-Ge) faaliyetleri içerdiğinden ve süreç içinde beklenmedik durumlarla veya yeni bulgularla karşılaşılabilirliğinden, esnekliğe olanak tanıyan **Çevik (Agile)** bir proje yönetimi metodolojisi benimsenecektir. Proje, kısa süreli (örn., 2-4 haftalık) iterasyonlara veya "sprint"lere bölünecektir. Her sprint sonunda, o sprint için belirlenen hedeflere ne ölçüde ulaşıldığı değerlendirilecek, elde edilen sonuçlar gözden geçirilecek, karşılaşılan zorluklar tartışılacak ve gerekirse bir sonraki sprintin veya projenin genel planı güncellenecektir. Bu yaklaşım, projenin dinamik doğasına uyum sağlamayı ve riskleri erken aşamada yönetmeyi kolaylaştıracaktır.
- **İş Paketleri (Work Packages):** Proje, ana hedeflere ve temel aşamalara paralel olarak mantıksal iş paketlerine ayrılacaktır. Örnek iş paketleri şunlar olabilir:
 - WP1: Literatür Taraması, Planlama ve Veri Erişimi
 - WP2: Veri Ön İşleme ve Öznitelik Çıkarım Altyapısı Geliştirme
 - WP3: Makine Öğrenmesi Modelleri Geliştirme ve Değerlendirme
 - WP4: Derin Öğrenme Modelleri Geliştirme ve Değerlendirme
 - WP5: Model Yorumlanabilirliği ve Sonuç Analizi
 - WP6: Raporlama, Sunum ve Proje Kapanışı
- **Zaman Çizelgesi:** Projenin tüm aşamalarını, iş paketlerini, alt görevlerini ve bunlar için öngörülen başlangıç-bitiş tarihlerini içeren detaylı bir iş-zaman çizelgesi (Gantt şeması veya tablo formatında) raporun "Proje Takvimi" bölümünde sunulacaktır.
- **Kaynak Yönetimi:** Projenin gerçekleştirilmesi için gerekli olan donanım (bilgisayar, GPU), yazılım (programlama dilleri, kütüphaneler, araçlar) ve insan kaynağı (proje yürütücüsü/öğrenci, proje danışmanı) planlaması yapılacak ve bu kaynakların proje süresince etkin kullanımı sağlanacaktır.
- **Risk Yönetimi:** Proje sürecinde karşılaşılabilecek potansiyel riskler (teknik, veriyle ilgili, zaman yönetimi vb.) ve bu riskleri azaltmaya veya ortadan kaldırmaya yönelik stratejiler, raporun "Riskler ve Çözüm Önerileri" bölümünde detaylı olarak ele alınacaktır.
- **İletişim ve Raporlama:** Proje danışmanı ile düzenli (örn., haftalık veya iki haftada bir)

toplantılar yapılarak projenin ilerleyişi hakkında bilgi verilecek, karşılaşılan sorunlar tartışılacak ve geri bildirim alınacaktır. Gerekirse kısa ilerleme raporları hazırlanacaktır.

- **Kullanılacak Araçlar:** Proje görevlerini ve ilerlemesini takip etmek için Trello, Asana gibi çevrimiçi proje yönetimi araçları veya basit bir elektronik tablo tabanlı Gantt şeması kullanılabilir. Geliştirilen kodların ve proje dokümanlarının versiyon kontrolü ve yönetimi için Git ve bir Git hosting platformu (örn., GitHub, GitLab) etkin bir şekilde kullanılacaktır. Bu, özellikle kod geliştirmede işbirliğini (eğer varsa) ve değişiklik takibini kolaylaştıracaktır.

Bu metodolojik yaklaşım, projenin hem bilimsel titizliğini hem de mühendislik disiplini koruyarak, belirlenen hedeflere ulaşılmasını ve yüksek kaliteli çıktılar üretilmesini amaçlamaktadır. Özellikle veri odaklı bir YZ projesinde, verinin kalitesi ve hazırlık süreçlerinin titizliği, model performansını doğrudan etkileyen en önemli faktörlerdendir. Bu nedenle, veri ön işleme ve öznitelik mühendisliği aşamalarına özel bir önem verilecektir. Aynı şekilde, model değerlendirmesinde kullanılacak olan test veri setinin eğitim sürecinden tamamen izole edilmesi, elde edilecek performans sonuçlarının güvenilirliği açısından hayati önem taşımaktadır. Bu, aşırı iyimser sonuçların önüne geçerek modelin gerçek dünya performansına dair daha gerçekçi bir fikir edinilmesini sağlar.¹⁶

Ek Bölümler :

• 5. Projenin Kapsamı ve Sınırları

○ Kapsam:

Bu proje, temel olarak halka açık, anonimleştirilmiş polisomnografi (PSG) veri setlerini kullanarak, uyku sırasında kaydedilen çeşitli fizyolojik sinyallerin (özellikle EKG, SpO2, EEG, EOG, EMG ve solunum sinyalleri) analizi yoluyla bireylerin gelecekteki kalp krizi riskini tahmin etmeye yönelik bir yapay zeka (YZ) modeli geliştirmeye odaklanacaktır. Proje kapsamında, kapsamlı bir veri ön işleme ve öznetelik mühendisliği süreci uygulanacak, ardından hem geleneksel makine öğrenmesi (ML) algoritmaları hem de çeşitli derin öğrenme (DL) mimarileri (CNN'ler, RNN/LSTM'ler, Transformer'lar ve bunların hibritleri dahil) tasarlanacak, eğitilecek ve performansları karşılaştırmalı olarak değerlendirilecektir. En iyi performansı gösteren model veya modeller belirlendikten sonra, bu modellerin karar verme süreçlerini anlamak ve klinik olarak anlamlı risk belirteçlerini saptamak amacıyla model yorumlanabilirliği teknikleri (SHAP, LIME vb.) uygulanacaktır. Projenin temel çıktıları, geliştirilmiş bir kalp krizi risk tahmin modeli prototipi, bu modelin performansını ve yorumlanabilirliğini detaylandıran kapsamlı bir araştırma raporu ve elde edilen bulguların sunulacağı bir sunum olacaktır.

○ Sınırlar:

Projenin hedefleri iddialı olmakla birlikte, belirli sınırlılıklarının da farkında olunması önemlidir:

- **Klinik Tanı Aracı Değildir:** Bu proje, bir klinik tanı aracı geliştirmeyi **hedeflememektedir**. Geliştirilen YZ modeli, bir risk değerlendirme, tarama veya erken uyarı aracı olarak düşünülmelidir. Modelin ürettiği tahminler, kesin bir tanı anlamına gelmez ve mutlaka bir tıp doktoru tarafından diğer klinik bilgilerle birlikte değerlendirilmelidir.
- **Veri Seti Sınırlılıkları:** Proje, mevcut halka açık veri setlerini kullanacaktır. Bu veri setlerinin doğasında bulunan sınırlılıklar (örneğin, belirli popülasyonlara özgü olması – yaş, etnik köken, coğrafi bölge; etiketlerin (örn., kalp krizi tanısı) kalitesi veya tanımındaki farklılıklar; bazı önemli klinik veya yaşam tarzı verilerinin eksik olması) geliştirilecek modelin genelleştirilebilirliğini ve tahmin doğruluğunu etkileyebilir. Örneğin, veri setlerindeki olası yanlılıklar, modelin farklı alt gruplarda farklı performans göstermesine neden olabilir.⁴
- **Donanım Geliştirme Yoktur:** Bu proje, yeni bir giyilebilir sensör, PSG cihazı veya veri toplama donanımı geliştirmeyi **içermemektedir**. Odak noktası, mevcut veriler üzerinde YZ algoritmaları geliştirmek ve uygulamaktır.
- **Tüm Risk Faktörlerinin Kapsanmaması:** Kalp krizi riski, genetik yatkınlık, detaylı beslenme alışkanlıkları, fiziksel aktivite düzeyi, stres yönetimi, çevresel faktörler ve tüm eşlik eden hastalıklar (komorbiditeler) gibi çok sayıda faktörden etkilenir. Kullanılacak PSG veri setleri, bu faktörlerin tamamını veya birçoğunu

içermeyebilir. Bu durum, modelin tahmin edebileceği riskin kapsamını sınırlar ve modelin açıklayamadığı varyansın bir kısmını oluşturabilir.

- **Gerçek Zamanlı Uygulama ve Klinik Validasyon Kapsam Dışıdır:** Geliştirilen modelin gerçek zamanlı bir izleme sistemine entegre edilmesi veya prospektif bir klinik çalışmada validasyonunun yapılması bu projenin kapsamı dışındadır. Ancak, bu proje bu tür gelecek çalışmalar için önemli bir temel ve öncü araştırma niteliği taşıyacaktır.
- **Nedensellik Değil, İlişki:** YZ modelleri genellikle verilerdeki karmaşık ilişkileri ve korelasyonları ortaya çıkarır. Bu proje, uyku parametreleri ile kalp krizi riski arasındaki güçlü ilişkileri modellemeyi amaçlasa da, bu ilişkilerin doğrudan bir nedensellik anlamına geldiğini iddia etmeyecektir. Nedensellik ilişkilerinin kurulması için farklı araştırma tasarımları (örn., randomize kontrollü çalışmalar) gereklidir.

Bu kapsam ve sınırlar, projenin neyi başarmayı hedeflediğini ve neleri başaramayacağını net bir şekilde ortaya koyarak, beklentilerin doğru yönetilmesine yardımcı olur. Özellikle, projenin bir araştırma prototipi olduğu ve doğrudan klinik uygulamaya hazır bir ürün olmadığı vurgusu, akademik dürüstlük ve sorumlu araştırma ilkeleri açısından önemlidir. Veri bağımlılığı, her YZ projesinin temel bir sınırlılığıdır ve bu projenin sonuçları da kullanılan veri setlerinin kalitesi ve özellikleriyle doğrudan ilişkili olacaktır.²³

● 6. Literatür Taraması / Mevcut Çalışmalar

- **Uyku ve Kardiyovasküler Hastalıklar Arasındaki Güçlü Bağlantı:**
Kapsamlı epidemiyolojik ve klinik araştırmalar, uyku süresi, kalitesi ve çeşitli uyku bozukluklarının kardiyovasküler hastalıklar (KVH) için önemli ve bağımsız risk faktörleri olduğunu kesin bir şekilde ortaya koymuştur.¹ Hem yetersiz (genellikle <6 saat) hem de aşırı (genellikle >9 saat) uyku süresinin, artmış hipertansiyon, koroner arter hastalığı (KAH), miyokard infarktüsü (MI) ve genel KVH mortalitesi riski ile ilişkili olduğu gösterilmiştir.² Uyku yoksunluğu, vücutta bir dizi olumsuz fizyolojik değişikliğe yol açar; bunlar arasında kan basıncında artış, sistemik inflamasyon belirteçlerinde (örn., C-reaktif protein) yükselme, stres hormonu olan kortizol seviyelerinde artış, iştah düzenleyici hormonlar olan leptin ve ghrelin dengesinde bozulma sonucu metabolik değişiklikler ve kilo alımı sayılabilir.¹ Bu faktörlerin her biri, KVH gelişimine katkıda bulunan bilinen risklerdir.
Özellikle Obstrüktif Uyku Apnesi (OSA), tekrarlayan üst solunum yolu tıkanıklıkları sonucu gece boyunca aralıklı hipoksemi (kanda oksijen düşüklüğü) ve hiperkapniye (kanda karbondioksit yüksekliği), sık uyanıklıklara (arousals) ve intratorasik basınçta büyük dalgalanmalara neden olan yaygın bir uyku bozukluğudur. OSA'nın, tedavi edilmediği takdirde, hipertansiyon, KAH, kalp yetmezliği, aritmiler (özellikle atriyal fibrilasyon) ve inme riskini önemli ölçüde artırdığı kanıtlanmıştır.³ Uyku apnesi sırasında yaşanan oksijen seviyelerindeki ve kan basıncındaki ani ve tekrarlayan dalgalanmalar, sempatik sinir sistemi aktivitesinde kronik bir artışa, endotel disfonksiyonuna, oksidatif strese ve inflamasyona yol açarak kalp ve damar sistemine

zarar verir.² Bir çalışma, tedavi edilmeyen uyku apnesinin kalp yetmezliği riskini 2-3 kat artırabileceğini belirtmektedir.³

- Uyku Verilerinden Elde Edilebilen Kardiyovasküler Risk Biyobelirteçleri:
Polisomnografi (PSG), uyku bozukluklarının tanısında altın standart olup, uyku sırasında birçok fizyolojik parametreyi kaydeder. Bu verilerden, KVH riskiyle ilişkili olabilecek değerli biyobelirteçler çıkarılabilir:
 - **Kalp Atım Hızı Değişkenliği (HRV):** EKG sinyalinin türetilen HRV, otonom sinir sisteminin (sempatik ve parasempatik dallar) kalp üzerindeki modülasyonunu yansıtan non-invaziv bir ölçüttür. Azalmış HRV, özellikle yüksek frekans (HF) bileşenindeki düşüş (parasempatik aktivitenin azalmasını gösterir), artmış kardiyovasküler risk, ani kardiyak ölüm ve genel mortalite ile güçlü bir şekilde ilişkilendirilmiştir. Uyku sırasındaki HRV analizi, özellikle farklı uyku evrelerindeki (NREM, REM) otonomik denge hakkında kritik bilgiler sunar.¹⁰ Nitekim, Sleep Heart Health Study (SHHS) verilerini kullanan bir çalışma, uyku HRV'sinin (özellikle HF bileşeni) uzun vadeli KVH sonuçları için bağımsız bir belirleyici olduğunu ve bir XGBoost modeli kullanılarak bu sonuçların %75.3 doğrulukla tahmin edilebildiğini göstermiştir.¹⁰ Bu çalışma, projenin HRV odaklı yaklaşımının sağlam bir bilimsel temele dayandığını göstermektedir.
 - **Kan Oksijen Satürasyonu (SpO₂) Örnekleri:** Gece boyunca SpO₂ seviyelerindeki düşüşler (desatürasyonlar), özellikle bunların sıklığı (Oksijen Desatürasyon İndeksi - ODI) ve derinliği, hipoksemik yükü yansıtır. Tekrarlayan hipoksemi atakları, uyku apnesinin ciddiyeti ve buna bağlı kardiyovasküler komplikasyon riski ile doğrudan ilişkilidir.³
 - **Uyku Mimarisi ve Sürekliliği:** Toplam uyku süresi, uyku verimliliği, farklı uyku evrelerinde (özellikle derin uyku - N3 ve REM uykusu) geçirilen süreler ve uyku bölünmelerinin (arousals) sıklığı gibi parametreler, uyku kalitesinin önemli göstergeleridir. Bozulmuş uyku mimarisi ve artmış uyku fragmantasyonu, artmış KVH riski ile ilişkilendirilmiştir. CinC Challenge 2018 veri seti, özellikle arousal etiketlerini içermesiyle bu tür analizler için değerlidir.⁸
- Yapay Zekanın (YZ) Kardiyovasküler Hastalık Tahminindeki Yükselen Rolü:
YZ, özellikle makine öğrenmesi (ML) ve derin öğrenme (DL) alt dalları, büyük ve karmaşık tıbbi veri setlerini (EKG, ekokardiyografi, elektronik sağlık kayıtları (EHR), genetik veriler, giyilebilir sensör verileri vb.) analiz ederek KVH'ların erken teşhisi, risk sınıflandırması, prognoz tahmini ve kişiselleştirilmiş tedavi stratejileri geliştirme konusunda devrim niteliğinde bir potansiyel sunmaktadır.⁴ YZ algoritmaları, insan uzmanların gözden kaçırabileceği veya geleneksel istatistiksel yöntemlerle modellenmesi zor olan karmaşık, doğrusal olmayan ilişkileri ve gizli örüntüleri tespit edebilir.⁴ Örneğin, bir YZ modelinin, acil servise başvuran hastalarda EKG sinyallerini analiz ederek tıkalı koroner arterleri saptamada deneyimli klinisyenlerden daha iyi (AUC 0.91 vs 0.65) ve geleneksel troponin T kan testiyle karşılaştırılabilir bir performans (AUC 0.71) gösterdiği rapor edilmiştir.¹⁶ Bu tür bulgular, YZ'nin tanısal süreçleri hızlandırma

ve doğruluğunu artırma potansiyelini açıkça göstermektedir.

- **Uyku Verileriyle Kardiyak Risk Tahmini Yapan Mevcut YZ Çalışmaları:**
Literatürde, PSG verilerinden (özellikle EKG, SpO2 ve solunum sinyallerinden) elde edilen öznitelikleri kullanarak spesifik uyku bozukluklarını (en yaygın olarak uyku apnesi) veya daha genel kardiyovasküler riski tahmin etmek için çeşitli ML modellerinin (SVM, RF, Lojistik Regresyon, XGBoost vb.) uygulandığı çok sayıda çalışma bulunmaktadır.¹⁰ Bu çalışmalar genellikle dikkatle tasarlanmış, mühendislik ürünü özniteliklere dayanır.
Son yıllarda, ham PSG sinyallerinden veya zaman serisi formatındaki özniteliklerden doğrudan özellik öğrenen DL modelleri (CNN'ler, RNN/LSTM'ler, Transformer'lar ve bunların hibrit mimarileri) bu alanda giderek daha fazla ilgi görmekte ve umut verici sonuçlar sunmaktadır.¹² Örneğin, PSG-MAE adlı bir öz-denetimli öğrenme (self-supervised learning) tabanlı ön-eğitim çerçevesi önerilmiş ve bu çerçevenin çok kanallı PSG sinyallerinden sağlam özellikler çıkarabildiği, ardından bu özelliklerin uyku evrelemesi (%83.7 doğruluk) ve OSA tespiti (%90.45 doğruluk) gibi görevlerde yüksek performans elde etmek için kullanılabileceği gösterilmiştir.¹³ Başka bir çalışmada, CNN ve Transformer mimarilerini birleştiren bir hibrit modelin, çeşitli yaşam öyküsü verilerinden (uyku kalitesi dahil) kalp hastalığı riskini tespit etmede geleneksel ML modellerinden (SVM, CNN, LSTM) daha iyi performans gösterdiği belirtilmiştir.¹⁵ Bu tür DL yaklaşımları, karmaşık zamansal bağımlılıkları ve sinyaller arası etkileşimleri daha etkin bir şekilde modelleyerek tahmin doğruluğunu artırma potansiyeline sahiptir.
- **Bu Projenin Mevcut Çalışmalara Katkısı ve Yenilikçi Yönleri:**
Bu proje, mevcut literatür birikiminin üzerine inşa ederek birkaç önemli ve yenilikçi katkı sunmayı hedeflemektedir:

1. **Kapsamlı ve Çok Modlu Öznitelik Entegrasyonu:** Proje, sadece tek bir fizyolojik sinyale veya sınırlı sayıda özneliğe odaklanmak yerine, çeşitli uyku fizyolojisi parametrelerini (HRV'nin farklı alt tipleri, SpO2'nin detaylı dinamikleri, uyku mimarisi özellikleri, EEG tabanlı beyin aktivitesi örüntüleri, arousallar ve solunum olayları) kapsamlı bir şekilde entegre ederek daha bütüncül bir risk değerlendirmesi yapmayı amaçlamaktadır.
2. **Gelişmiş YZ Modellerinin Karşılaştırmalı Değerlendirilmesi:** Hem iyi bilinen geleneksel ML algoritmalarını hem de en son teknolojiye sahip DL mimarilerini (özellikle farklı sinyal türleri için optimize edilmiş CNN'ler, zamansal dinamikler için LSTM'ler, uzun vadeli bağımlılıklar ve modaliteler arası etkileşimler için Transformer'lar ve bunların potansiyelini birleştiren hibrit modeller) aynı veri setleri üzerinde sistematik ve karşılaştırmalı olarak değerlendirecektir. Bu, hangi yaklaşımların uyku tabanlı kalp krizi riski tahmini için en uygun olduğuna dair değerli bilgiler sunacaktır.
3. **Model Yorumlanabilirliğine Özel Vurgu:** Yüksek tahmin doğruluğunun yanı sıra, modelin neden belirli bir tahminde bulunduğunu anlamak da büyük önem taşımaktadır. Proje, SHAP ve LIME gibi modern model yorumlanabilirliği

tekniklerini kullanarak, geliştirilen modellerin (özellikle DL modellerinin) "kara kutu" özelliğini azaltmayı ve kalp krizi riskiyle en güçlü ilişkisi olan spesifik uyku biyobelirteçlerini ve örüntülerini belirlemeyi hedeflemektedir. Bu, sadece modelin güvenilirliğini artırmakla kalmayacak, aynı zamanda potansiyel klinik içgörüler ve yeni hipotezler üretebilecektir. Bu, özellikle "kara kutu" modellerin klinik kabulündeki en büyük engellerden biri olan şeffaflık eksikliğini gidermeye yönelik önemli bir adımdır.⁴

4. **Spesifik Bir Sonlanım Noktasına Odaklanma:** Genel KVH riski yerine, daha spesifik ve ciddi bir sonlanım noktası olan "kalp krizi riski"ne odaklanmak, modelin klinik olarak daha hedefe yönelik ve eyleme geçirilebilir bilgiler sunmasını sağlayabilir.
5. **Tekrarlanabilirlik ve Açıklık:** Proje, metodolojisini, kullanılan veri setlerini (halka açık olanlar için erişim bilgileriyle birlikte), kodlarını (uygun kısımlarını, örneğin GitHub üzerinden) ve sonuçlarını açık ve şeffaf bir şekilde belgeleyerek bilimsel toplulukta tekrarlanabilirliği ve daha ileri araştırmaları teşvik etmeyi amaçlamaktadır.

Tablo 4, literatürdeki bazı önemli mevcut çalışmaları ve bu projenin onlara kıyasla konumunu özetlemektedir:

Tablo 4: Önemli Mevcut Çalışmaların Özeti ve Karşılaştırılması

Çalışma (Yazar(lar) ve Yıl, Kaynak ID)	Amaç/Odak	Kullanılan Veri Seti/Veri Türü	Kullanılan YZ Yöntem(ler)i	Temel Bulgular/Performans	Bu Projenin Farklılaştığı Nokta / Katkısı
Zhang et al., 2020 ¹⁰	Uyku HRV'si ile uzun vadeli KVH sonuçları arasındaki ilişki ve otomatik KVH tahmini	SHHS (N=2111), PSG (EKG)	Zaman/Freka ns domeni HRV, XGBoost	Azalmış uyku HRV'si (özellikle HF) KVH ile ilişkili. Model doğruluğu %75.3.	Daha geniş yelpazede uyku parametreleri (SpO2, EEG, arousallar vb.) entegre edilecek. Daha çeşitli ve gelişmiş DL modelleri (örn., Transformer) denenecek. Kalp krizine spesifik odaklanma.
Wang et al., 2022 ¹¹	OSA hastalarında hipertansiyon riskini ML ile tahmin etme	Klinik PSG verileri (N=1493), 27 değişken	LR, GBM, XGBoost, AdaBoost, Bagging, MLP	GBM en iyi (AUC=0.873, Acc=%88.5). SHAP ile yorumlama.	Kalp krizi riskine odaklanma. Daha geniş ve farklı veri setleri (SHHS, CinC) kullanılacak. Transformer gibi daha yeni DL mimarileri eklenecek.
Z. Zhang et al., 2024 ¹³	Çok kanallı PSG için öz- denetimli ön-	Çeşitli PSG veri setleri (EEG,	Maskeli Oto- kodlayıcı (MAE),	Uyku evrelemede %83.7, OSA tespitinde %90.45	PSG-MAE gibi ön-eğitilmiş modellerin kalp krizi riski tahminine uygulanabilirliği

	eğitim (PSG-MAE) ile uyku olayı izleme	EOG, EMG, EKG vb.)	CNN, RNN	doğruluk.	araştırılacak. Yorumlanabilirlik analizleri eklenecek.
Devia et al., 2024 ¹⁵	CNN-Transformer hibrit modeli ile yaşam öyküsü verilerinden kalp hastalığı tespiti	Yaşam öyküsü verileri (uyku kalitesi dahil)	Hibrit CNN-Transformer	Geleneksel ML ve saf DL modellerinden daha iyi performans.	PSG'den elde edilen detaylı fizyolojik uyku verilerine odaklanılacak. Uykuya özgü öznitelikler ve sinyal işleme teknikleri kullanılacak.
Büscher et al., 2025 (ACC.25) ¹⁶	EKG'den tıkalı koroner arterleri saptamak için YZ modeli	Acil servis EKG verileri	Derin Öğrenme Modeli	Model AUC=0.91 (iç test), 0.85 (dış validasyon). Klinisyenlerden daha iyi.	EKG'ye ek olarak çoklu PSG sinyalleri (SpO2, EEG vb.) kullanılacak. Uyku bağlamındaki EKG değişikliklerine odaklanılacak.

Bu karşılaştırma, projenin mevcut bilgi birikimine nasıl eklemlendiğini ve hangi alanlarda yenilik getirmeyi amaçladığını göstermektedir. Özellikle, çoklu uyku modalitelerinden gelen bilgiyi birleştiren, gelişmiş DL mimarilerini kullanan ve model yorumlanabilirliğine güçlü bir vurgu yapan bir yaklaşım, literatürdeki mevcut boşlukları doldurma potansiyeline sahiptir.

- **7. Beklenen Sonuçlar ve Katkıları**

Bu projenin başarıyla tamamlanması durumunda, hem bilimsel literatüre hem de potansiyel klinik uygulamalara yönelik önemli sonuçlar ve katkılar elde edilmesi beklenmektedir.

- **Bilimsel Katkılar:**

- **Uyku-Kardiyak İlişkisinin Derinlemesine Anlaşılması:** Proje, uyku fizyolojisinin çeşitli parametreleri (özellikle HRV'nin farklı bileşenleri, SpO2 desatürasyon örüntüleri, uyku mimarisinin detayları, EEG tabanlı beyin aktivitesi ve kortikal arousallar gibi) ile spesifik bir kardiyovasküler sonlanım noktası olan kalp krizi riski arasındaki karmaşık, doğrusal olmayan ve potansiyel olarak etkileşimli ilişkilerin daha iyi anlaşılmasına katkı sağlayacaktır. Yorumlanabilirlik analizleri sayesinde, hangi uyku özelliklerinin bu riskle en güçlü şekilde ilişkili olduğu ve bu ilişkilerin doğası (artırıcı/azaltıcı etki) hakkında yeni bilgiler ortaya konabilir.
- **YZ Modellerinin Karşılaştırmalı Performans Analizi:** Proje, farklı yapay zeka modellerinin (geleneksel makine öğrenmesi algoritmalarından en yeni derin öğrenme mimarilerine, özellikle de Transformer tabanlı ve hibrit modellere kadar) çok modlu PSG verilerinden kalp krizi riskini tahmin etme performansının kapsamlı ve sistematik bir karşılaştırmasını sunacaktır. Bu, gelecekteki benzer çalışmalara model seçimi konusunda rehberlik edebilir.
- **Yeni Biyobelirteçlerin veya Örüntülerin Keşfi:** YZ modelleri, özellikle de derin öğrenme, insan uzmanların veya geleneksel istatistiksel yöntemlerin gözden kaçırabileceği, kalp krizi riski için önemli olan yeni veya daha önce yeterince takdir edilmemiş uykuyla ilişkili biyobelirteçleri veya fizyolojik örüntüleri belirleme potansiyeline sahiptir.
- **Metodolojik Katkı:** Proje, büyük ölçekli PSG veri setlerinin işlenmesi, çok modlu özniteliklerin çıkarılması ve entegrasyonu, gelişmiş YZ modellerinin uyku verilerine uygulanması ve bu modellerin yorumlanması konularında iyi belgelenmiş bir metodoloji ve tekrarlanabilir sonuçlar sunarak literatüre katkıda bulunacaktır.

- **Teknolojik Katkılar:**

- **Risk Tahmin Modeli Prototipi:** Projenin en somut çıktısı, uyku verilerine dayanarak kalp krizi riskini erken aşamada ve non-invaziv olarak tahmin edebilen yeni bir yapay zeka tabanlı model prototipi (veya en iyi performans gösteren modellerden oluşan bir set) olacaktır.
- **Analiz Süreci (Pipeline):** PSG verilerinin alınmasından, ön işlenmesine, öznitelik çıkarımına, model eğitime ve değerlendirilmesine kadar olan tüm süreçleri otomatize eden veya kolaylaştıran etkili bir yazılım sürecinin (kodlar, scriptler) oluşturulması hedeflenmektedir. Bu pijam, gelecekteki araştırmalar için de kullanılabilir bir kaynak olabilir.
- **Gelecek Teknolojilere Temel Oluşturma:** Geliştirilen model ve algoritmalar, gelecekte giyilebilir sensör teknolojileri (akıllı saatler, bileklikler, uyku takip

cihazları) veya daha basit evde uyku testi cihazları ile entegre edilebilecek bir yazılım modülüne veya sistemine temel oluşturabilir. Bu, risk değerlendirmesinin daha geniş kitlelere yayılmasını ve kişiselleştirilmiş sağlık takibini mümkün kılabilir.

○ **Toplumsal ve Ekonomik Katkıları:**

- **Halk Sağlığının İyileştirilmesi:** Kalp krizlerinin erken teşhisine ve dolayısıyla önlenmesine yardımcı olarak, toplumun genel kardiyovasküler sağlığının iyileştirilmesine potansiyel bir katkı sunabilir. Erken uyarılar, bireylerin yaşam tarzı değişiklikleri yapmaları veya zamanında tıbbi yardım almaları için kritik bir fırsat yaratabilir.
- **Sağlık Hizmetleri Maliyetlerinin Azaltılması:** Yüksek riskli bireylerin erken dönemde ve daha düşük maliyetli yöntemlerle belirlenmesi, pahalı acil tedavilere, uzun süreli hastane yatışlarına ve kronik bakım ihtiyacına olan gereksinimi azaltarak sağlık hizmetleri maliyetlerinin uzun vadede düşürülmesine yardımcı olabilir. Önleyici tedbirler genellikle tedavi edici müdahalelerden daha maliyet etkindir.⁶
- **Bireysel Farkındalık ve Güçlendirme:** Bireylerin kendi uyku kaliteleri ve potansiyel sağlık riskleri hakkında daha bilinçli olmalarını ve sağlıkları konusunda proaktif adımlar atmalarını teşvik edebilir.
- **Klinik Karar Desteği:** Geliştirilen model, bir tanı aracı olmasa da, klinisyenler için hastalarının kalp krizi riskini değerlendirmede ek bir bilgi kaynağı ve karar destek aracı olarak potansiyel taşıyabilir. Özellikle yorumlanabilirlik analizlerinden elde edilen bilgiler, hangi uyku parametrelerine dikkat edilmesi gerektiği konusunda klinisyenlere yol gösterebilir.

○ **Potansiyel Çıktılar (Deliverables):**

- Eğitilmiş, test edilmiş ve performansı değerlendirilmiş bir veya daha fazla kalp krizi risk tahmin modeli (kodları ve ağırlıklarıyla birlikte).
- Modellerin performansını detaylandıran kapsamlı değerlendirme metrikleri, tablolar, grafikler (ROC eğrileri, P-R eğrileri vb.) ve istatistiksel analizler.
- Model yorumlanabilirliğine ilişkin bulgular: önemli özniteliklerin listesi, SHAP/LIME analiz sonuçları ve görselleştirmeleri.
- Proje sürecini, kullanılan yöntemleri, elde edilen bulguları ve varılan sonuçları içeren, bilimsel standartlara uygun, kapsamlı bir teknik rapor (tez veya bitirme projesi raporu).
- Proje bulgularının etkili bir şekilde sunulduğu bir sözlü sunum ve poster (gerekirse).
- Projenin sonuçlarının niteliğine bağlı olarak, bulguların hakemli bir dergide yayınlanması veya ulusal/uluslararası bir bilimsel konferansta sunulması için bir makale veya bildiri taslağı materyali.

Bu beklenen sonuçlar ve katkılar, projenin sadece bir akademik çalışma olmanın ötesinde,

gerçek dünya problemlerine çözüm üretme ve hem bilimsel hem de toplumsal alanda pozitif bir etki yaratma potansiyeline sahip olduğunu göstermektedir. Özellikle, yorumlanabilir YZ modelleri aracılığıyla uyku ve kalp sağlığı arasındaki bağlantıya dair elde edilecek derinlemesine anlayış, gelecekteki klinik araştırmalar ve kişiselleştirilmiş tıp uygulamaları için yeni kapılar açabilir. Proje, aynı zamanda, daha gelişmiş araştırmalara (örneğin, farklı veri türlerinin – genetik, yaşam tarzı, çevresel faktörler – entegre edildiği longitudinal çalışmalar veya modelin giyilebilir sensör verileriyle gerçek zamanlı izleme sistemlerine uyarlanması) zemin hazırlayabilir.

- **8. Riskler ve Çözüm Önerileri**

Her araştırma ve geliştirme projesinde olduğu gibi, bu projede de süreç boyunca karşılaşılabilecek çeşitli potansiyel riskler bulunmaktadır. Bu risklerin erken aşamada tanımlanması ve bunlara yönelik proaktif çözüm önerilerinin geliştirilmesi, projenin başarıyla tamamlanma olasılığını artıracaktır.

- **Veri İle İlgili Riskler:**

- **Risk 1: Yetersiz Veri Erişimi veya Kalitesi:** Kalp krizi riski tahmini için uygun, yeterli büyüklükte ve kalitede halka açık PSG veri seti bulamama, veri setlerine erişimde teknik veya bürokratik sorunlar yaşama.
- **Çözüm Önerisi 1:** Projenin en başında kapsamlı bir veri seti araştırması yapmak, birden fazla potansiyel veri setini (örn., SHHS, CinC Challenge, MESA) ve bunların erişim koşullarını (veri kullanım anlaşmaları, etik onaylar vb.) detaylıca incelemek. PhysioNet gibi güvenilir platformlara öncelik vermek. Gerekirse, veri erişimi için ilgili kurumlara resmi başvuruları zamanında yapmak. Alternatif olarak, daha küçük ama iyi karakterize edilmiş veri setleriyle başlamak ve metodolojiyi bunlar üzerinde geliştirmek.
- **Risk 2: Veri Kalitesi Sorunları:** Seçilen veri setlerinde yüksek oranda eksik veri, gürültü, artefakt veya etiketleme hataları bulunması ve bunların model performansını olumsuz etkilemesi.
- **Çözüm Önerisi 2:** Sağlam ve literatürde kabul görmüş veri ön işleme, gürültü filtreleme ve artefakt giderme/işaretleme teknikleri uygulamak. Eksik veri yönetimi için uygun stratejiler (örn., ortalama/medyan ile doldurma, regresyon tabanlı imputation, çoklu imputation veya eksik veriyi tolere edebilen algoritmalar kullanma) geliştirmek. Sinyal kalitesi çok düşük olan segmentleri veya kayıtları analizden çıkarmak veya analizdeki ağırlığını azaltmak. Etiketlerin (özellikle sonlanım noktası etiketlerinin) doğruluğunu ve tutarlılığını mümkün olduğunca teyit etmeye çalışmak.
- **Risk 3: Veri Seti Yanlılıkları (Bias):** Kullanılan veri setlerinin belirli demografik grupları (örn., yaş, cinsiyet, etnik köken, sosyoekonomik durum) veya coğrafi bölgeleri yetersiz temsil etmesi sonucu modelin bu gruplar için daha düşük performans göstermesi ve mevcut sağlık eşitsizliklerini pekiştirmesi.⁴
- **Çözüm Önerisi 3:** Veri setlerinin demografik ve klinik özelliklerini dikkatlice analiz etmek, potansiyel yanlılıkların farkında olmak ve bunları raporlamak. Mümkünse, farklı kaynaklardan gelen veri setlerini birleştirerek veya

ağırlıklandırma teknikleri kullanarak veri çeşitliliğini artırmaya çalışmak (proje kapsamı ve süresi dahilindeyse). Modelin farklı alt gruplar (örn., erkekler vs. kadınlar, farklı yaş grupları) üzerindeki performansını ayrı ayrı değerlendirerek adalet (fairness) analizleri yapmak. Sonuçları yorumlarken bu potansiyel yanlılıkları dikkate almak.

○ **Model Geliştirme ve Performans İle İlgili Riskler:**

- **Risk 4: Beklenen Performans Düzeyine Ulaşılamaması:** Geliştirilen YZ modellerinin, hedeflenen performans düzeyine (örn., $AUC > 0.80$ veya literatürdeki benzer çalışmalardan daha iyi bir sonuç) ulaşamaması.
- **Çözüm Önerisi 4:** Farklı ve daha sofistike öznitelik mühendisliği yaklaşımlarını (örn., dalgacık tabanlı öznitelikler, doğrusal olmayan dinamik analiz öznitelikleri) denemek. Daha geniş bir yelpazede ML ve DL mimarilerini (özellikle literatürde umut vaat eden hibrit modeller veya Transformer'lar) sistematik olarak test etmek. Hiperparametre optimizasyonunu daha kapsamlı ve titiz bir şekilde (örn., Bayesian optimizasyon ile) yapmak. Literatürdeki başarılı yaklaşımlardan ve açık kaynak kodlardan ilham almak. Model karmaşıklığını veri miktarına göre ayarlamak.
- **Risk 5: Derin Öğrenme Modellerinde Aşırı Öğrenme (Overfitting):** Karmaşık DL modellerinin eğitim verilerine aşırı uyum sağlayarak test verilerinde düşük genelleme performansı göstermesi.
- **Çözüm Önerisi 5:** Çapraz doğrulama (cross-validation) stratejilerini doğru uygulamak. Erken durdurma (early stopping) mekanizmasını etkin kullanmak. Dropout, L1/L2 regülerizasyonu, batch normalization gibi regülerizasyon tekniklerini uygun şekilde entegre etmek. Veri artırma (data augmentation) tekniklerini (zaman serisi verileri için uygun olanları, örn., gürültü ekleme, ölçekleme, zamanla kaydırma) dikkatlice uygulamak. Test veri setini model geliştirme ve ayarlama süreçlerinden kesinlikle ayrı tutmak.
- **Risk 6: Yetersiz Hesaplama Kaynağı:** Özellikle büyük veri setleri üzerinde karmaşık derin öğrenme modellerinin eğitimi için yeterli GPU (Grafik İşlem Birimi) süresine veya kapasitesine sahip olmama.
- **Çözüm Önerisi 6:** Google Colab Pro, Kaggle Kernels gibi ücretsiz veya düşük maliyetli bulut tabanlı GPU hizmetlerini etkin bir şekilde kullanmak. Model karmaşıklığını mevcut kaynaklara göre optimize etmek (örn., daha az katmanlı modeller, transfer öğrenme ile önceden eğitilmiş modelleri kullanma). Mümkünse, üniversite veya bölümün araştırma laboratuvarlarındaki yüksek performanslı hesaplama kümelerinden (HPC) yararlanmak için başvuruda bulunmak. Eğitim süreçlerini daha verimli hale getirmek için kod optimizasyonu yapmak.

Yorumlanabilirlik ve Sonuçların Anlamlılığı İle İlgili Riskler:

- **Risk 9: Yorumlanabilirlik Zorlukları:** Özellikle karmaşık DL modellerinin karar verme süreçlerinin yorumlanmasının zor olması veya SHAP/LIME gibi tekniklerden elde edilen yorumların klinik olarak anlamlı veya eyleme geçirilebilir olmaması.

- **Çözüm Önerisi 9:** Farklı yorumlanabilirlik araçlarını ve yaklaşımlarını (örn., attention mekanizmalarının görselleştirilmesi, vekil modeller) denemek. Yorumlanabilirlik sonuçlarını, alan uzmanlarıyla (mümkünse bir tıp doktoru veya uyku/kardiyoloji uzmanıyla) tartışarak klinik anlamlılığını ve fizyolojik makullüğünü değerlendirmek. Daha basit ve doğası gereği yorumlanabilir olan modellerle (örn., Lojistik Regresyon, Karar Ağaçları) karşılaştırmalı analizler yaparak DL modellerinin öğrendiği örüntülerin tutarlılığını kontrol etmek. Özniteliklerin önem sıralamasının farklı modellerde veya veri alt kümelerinde ne kadar kararlı olduğunu incelemek.

Bu risklerin ve çözüm önerilerinin proaktif bir şekilde yönetilmesi, projenin bilimsel kalitesini, teknolojik başarısını ve zamanında tamamlanmasını sağlamada kilit rol oynayacaktır. Risk yönetimi, sadece olası sorunları öngörmek değil, aynı zamanda bu sorunlar ortaya çıktığında hızlı ve etkili bir şekilde müdahale edebilmek için hazırlıklı olmayı da içerir.

• 10. Gerekli Kaynaklar

Bu projenin başarıyla yürütülmesi ve hedeflerine ulaşması için çeşitli donanım, yazılım, veri ve insan kaynaklarına ihtiyaç duyulacaktır. Bu kaynaklar aşağıda detaylandırılmıştır:

○ Donanım:

- **Yüksek Performanslı Kişisel Bilgisayar:** Proje geliştirme, veri analizi, kodlama ve raporlama işlemleri için yeterli işlem gücüne (modern çok çekirdekli CPU, örn., Intel Core i7/i9 veya AMD Ryzen 7/9 serisi), yeterli belleğe (en az 16 GB RAM, tercihen 32 GB veya üzeri) ve büyük veri setlerini depolayabilecek yeterli disk alanına (en az 1 TB SSD) sahip bir kişisel bilgisayar veya dizüstü bilgisayar.
- **Grafik İşlem Birimi (GPU):** Özellikle derin öğrenme modellerinin (CNN, LSTM, Transformer vb.) eğitimi, önemli miktarda paralel hesaplama kapasitesi gerektirir. Bu nedenle, NVIDIA tarafından üretilen CUDA özellikli bir GPU'ya sahip bir iş istasyonu (örn., GeForce RTX serisi, Quadro serisi) veya bulut tabanlı GPU hizmetlerine (örneğin, Google Colab Pro'nun sunduğu Tesla T4/P100/V100 GPU'ları, Amazon Web Services (AWS) EC2 P3/G4 örnekleri, Microsoft Azure NC serisi VM'ler) erişim kritik öneme sahiptir. Yeterli GPU kaynağı olmadan, DL modellerinin eğitimi pratik olmayacak kadar uzun sürebilir ve bu da proje takvimini olumsuz etkileyebilir.

○ Yazılım:

- **İşletim Sistemi:** Windows, macOS veya Linux (özellikle Ubuntu gibi geliştirici dostu bir dağıtım).
- **Programlama Dili:** Python (versiyon 3.8 veya üzeri), bilimsel hesaplama, veri bilimi ve yapay zeka alanlarındaki zengin kütüphane ekosistemi nedeniyle tercih edilecektir.
- **Temel Veri Bilimi ve Sayısal Hesaplama Kütüphaneleri:**
 - NumPy: Çok boyutlu diziler ve matrislerle çalışmak için temel paket.

- Pandas: Veri manipölasyonu ve analizi için güçlü veri yapıları (DataFrame vb.) sunar.
- Scikit-learn: Kapsamlı bir makine öğrenmesi kütüphanesi (sınıflandırma, regresyon, kümeleme, boyut azaltma, model seçimi, ön işleme araçları içerir).
- Matplotlib ve Seaborn: Veri görselleştirme ve grafik çizimi için.
- SciPy: Bilimsel ve teknik hesaplamalar için (sinyal işleme, optimizasyon, istatistik vb. modüller içerir).
- **Sinyal İşleme ve Uyku Analizi Kütüphaneleri:**
 - MNE-Python: EEG, MEG, EKG gibi nörofizyolojik sinyallerin analizi, görselleştirilmesi ve işlenmesi için güçlü bir kütüphane.
 - PyWavelets: Dalgacık dönüşümü tabanlı sinyal analizi için.
 - YASA (Yet Another Sleep Analyzer): Otomatik uyku evrelemesi, yavaş dalga tespiti, uyku iğciği tespiti gibi uyku analizi görevleri için kullanışlı bir araç.
 - Diğer spesifik sinyal işleme veya uyku analizi kütüphaneleri (örn., hrv-analysis paketi).
- **Derin Öğrenme Kütüphaneleri:**
 - TensorFlow (Google tarafından geliştirilen) ve Keras (TensorFlow üzerinde çalışan üst düzey bir API): Derin öğrenme modelleri oluşturmak, eğitmek ve dağıtmak için popüler ve kapsamlı bir platform.
 - Veya PyTorch (Facebook AI Research tarafından geliştirilen): Dinamik hesaplama grafikleri ve Pythonic yapısıyla özellikle araştırmacılar arasında popüler olan bir diğer güçlü derin öğrenme kütüphanesi.
- **Hiperparametre Optimizasyon Kütüphaneleri:**
 - Optuna: Otomatik hiperparametre optimizasyonu için modern bir kütüphane.
 - Hyperopt: Dağıtık asenkron hiperparametre optimizasyonu için.
 - KerasTuner: Keras modelleri için hiperparametre ayarını kolaylaştıran bir araç.
- **Model Yorumlanabilirliği Kütüphaneleri:**
 - SHAP: SHapley Additive exPlanations değerlerini hesaplamak ve görselleştirmek için.
 - LIME: Local Interpretable Model-agnostic Explanations uygulamak için.
- **Entegre Geliştirme Ortamı (IDE) veya Metin Düzenleyici:**
 - Visual Studio Code (VS Code), PyCharm Community/Professional Edition, Spyder gibi Python geliştirmeye uygun bir IDE.
 - Jupyter Notebook veya JupyterLab: Etkileşimli kodlama, veri analizi ve görselleştirme için ideal bir ortam.
- **Sürüm Kontrol Sistemi:**
 - Git: Kod ve proje dosyalarının versiyonlarını takip etmek için dağıtık bir sürüm kontrol sistemi.
 - GitHub, GitLab veya Bitbucket: Git tabanlı projeleri barındırmak, işbirliği yapmak ve kod paylaşmak için bulut tabanlı platformlar.
- **Referans Yönetim Yazılımı:**

- Zotero, Mendeley veya EndNote: Bilimsel makaleleri ve referansları yönetmek, literatür taramasını organize etmek ve rapor yazımında atıfları kolaylaştırmak için.
- **Kelime İşlemci ve Sunum Yazılımı:**
 - Microsoft Office (Word, PowerPoint) veya LibreOffice (Writer, Impress) veya LaTeX (bilimsel raporlar için).
- **Veri Setleri:**
 - Projenin temelini oluşturacak olan, PhysioNet (örn., Sleep Heart Health Study - SHHS, Computing in Cardiology Challenge 2018 veri seti, MESA Sleep vb.) gibi güvenilir ve halka açık platformlardan elde edilecek anonimleştirilmiş polisomnografi (PSG) veri setleri. Bu veri setlerine erişim için gerekli kayıt ve veri kullanım anlaşması (Data Use Agreement - DUA) süreçleri (eğer varsa) titizlikle takip edilecektir.
- **İnsan Kaynağı:**
 - **Proje Yürütücüsü (Öğrenci):** Projenin tüm aşamalarının planlanmasından, uygulanmasından, analizlerin yapılmasından ve raporlanmasından sorumlu olacak ana kişi.
 - **Proje Danışmanı (Akademik Personel):** Projenin bilimsel ve teknik yönlendirmesini yapacak, metodolojik destek sağlayacak, ilerlemeyi denetleyecek ve karşılaşılan sorunların çözümünde rehberlik edecek deneyimli bir öğretim üyesi.

Diğer Kaynaklar:

- **Bilimsel Literatüre Erişim:** Proje süresince literatür taraması ve güncel araştırmaların takibi için ilgili bilimsel makalelere, dergilere ve konferans bildirilerine erişim. Bu genellikle üniversite kütüphanesinin sağladığı veritabanı abonelikleri (örn., IEEE Xplore, PubMed, ScienceDirect, ACM Digital Library) aracılığıyla sağlanacaktır.
- **Eğitim Materyalleri:** Gerekli yazılım ve kütüphanelerin kullanımı, yeni algoritmaların öğrenilmesi veya belirli analiz tekniklerinin uygulanması için çevrimiçi kurslara (Coursera, edX, Udemy vb.), dokümantasyonlara ve eğitim materyallerine erişim.

Bu kaynakların proje başlangıcında planlanması ve temin edilmesi, projenin sorunsuz ve verimli bir şekilde ilerlemesi için hayati öneme sahiptir. Özellikle GPU erişimi ve büyük veri setlerinin yönetimi gibi konular, projenin erken aşamalarında çözüme kavuşturulmalıdır. Açık kaynaklı yazılımların ve kütüphanelerin yaygın kullanımı, projenin maliyet etkinliğini artırırken, güçlü bir topluluk desteğinden de yararlanılmasını sağlar.

● **11. Etik Hususlar (Ethical Considerations)**

Bu proje, insanlardan elde edilen hassas tıbbi verilerle (polisomnografi kayıtları) çalıştığı ve bireylerin sağlık durumlarıyla ilgili potansiyel olarak önemli çıkarımlar yapmayı amaçladığı için etik hususlar son derece büyük bir önem taşımaktadır. Projenin tüm aşamalarında, en yüksek etik standartlara ve sorumlu araştırma ilkelerine bağlı kalınacaktır.

- **Veri Gizliliği, Güvenliği ve Anonimlik:** ⁴

- **Temel Prensipte:** Projede kullanılacak tüm veri setlerinin tamamen anonimleştirilmiş olması esastır. Katılımcıların kimliklerini doğrudan veya dolaylı olarak açığa çıkarabilecek hiçbir tanımlayıcı bilgi (isim, adres, kimlik numarası vb.) kullanılmayacak ve bu tür bilgilerle çalışılmayacaktır.
- **Veri Kaynaklarının Etik Onayı:** Eğer halka açık veri setleri (örn., PhysioNet üzerinden erişilenler) kullanılacaksa, bu veri setlerinin orijinal toplayıcıları tarafından ilgili etik kurullardan (Institutional Review Board - IRB veya eşdeğeri) gerekli onayların alındığı ve katılımcılardan uygun şekilde bilgilendirilmiş onam (informed consent) alındığı teyit edilecektir. PhysioNet gibi platformlar genellikle bu tür bilgileri veri seti açıklamalarında sunar.
- **Veri Saklama ve İşleme Güvenliği:** Anonimleştirilmiş dahi olsa, verilerin saklanması ve işlenmesi sırasında yetkisiz erişimi, veri sızıntısını veya kötüye kullanımı önlemek için gerekli teknik ve idari güvenlik önlemleri alınacaktır. Bu, verilerin şifreli depolanmasını, erişimin sadece yetkili kişilerle sınırlandırılmasını ve güvenli ağ bağlantılarının kullanılmasını içerebilir. Veri minimizasyonu ilkesi gözetilerek, sadece proje amaçları için gerekli olan verilerle çalışılacaktır. GDPR (Genel Veri Koruma Yönetmeliği) gibi uluslararası veri koruma düzenlemelerinin prensipleri dikkate alınacaktır.⁴
- **Algoritmik Yanlılık (Bias) ve Adalet (Fairness):**⁴
 - **Potansiyel Risk:** Yapay zeka modelleri, eğitildikleri verilerdeki mevcut yanlılıkları öğrenebilir ve bu yanlılıkları pekiştirebilir. Eğer kullanılan veri setleri belirli demografik grupları (örn., yaş, cinsiyet, etnik köken, sosyoekonomik durum) yetersiz temsil ediyorsa veya bu gruplar hakkında hatalı bilgiler içeriyorsa, geliştirilen model bu gruplar için daha düşük performans gösterebilir veya adil olmayan tahminlerde bulunabilir. Bu durum, mevcut sağlık eşitsizliklerinin artmasına yol açabilir.²⁹
 - **Azaltma Stratejileri:** Bu potansiyel yanlılıkların farkında olunacak ve projenin başından itibaren dikkate alınacaktır. Kullanılacak veri setlerinin demografik dağılımı ve potansiyel temsil sorunları incelenecek ve raporlanacaktır. Mümkünse ve proje kapsamı elveriyorsa, farklı alt gruplar (örn., erkekler vs. kadınlar, farklı yaş aralıkları, farklı etnik kökenler - eğer veri setinde bu bilgiler mevcutsa) üzerinde modelin performansı ayrı ayrı değerlendirilerek adalet (fairness) analizleri yapılacaktır. Modelin yorumlanabilirliği çalışmaları, modelin belirli gruplara karşı sistematik bir hata yapıp yapmadığını anlamada yardımcı olabilir. Sonuçlar yorumlanırken ve modelin potansiyel uygulamaları tartışılırken bu yanlılık riskleri açıkça belirtilecektir.
- **Bilgilendirilmiş Onam (Informed Consent):**²⁹
 - Bu proje, mevcut (ikincil) veri setleri üzerinde bir analiz çalışması olduğu için, proje yürütücüsü tarafından doğrudan katılımcılardan yeni bir bilgilendirilmiş onam alınması söz konusu olmayacaktır. Ancak, kullanılacak tüm veri setlerinin, orijinal veri toplama süreçlerinde, katılımcılardan verilerinin araştırma amaçlı (ve

genellikle anonimleştirilmiş olarak) kullanılabileceğine dair etik standartlara uygun şekilde bilgilendirilmiş onam alındığı varsayılacak ve bu durum teyit edilmeye çalışılacaktır (genellikle veri seti sağlayıcıları bu konuda bilgi verir).

○ **Şeffaflık, Hesap Verebilirlik ve Yorumlanabilirlik:** ¹¹

- **Şeffaflık:** Projenin metodolojisi, kullanılan veri setleri (erişim bilgileriyle birlikte), uygulanan ön işleme adımları, geliştirilen modellerin mimarileri, eğitim süreçleri ve elde edilen tüm sonuçlar (hem pozitif hem de negatif) açık, dürüst ve detaylı bir şekilde raporlanacaktır.
- **Yorumlanabilirlik:** Modelin karar verme süreçlerini anlamak ve "kara kutu" etkisini azaltmak için SHAP, LIME gibi model yorumlanabilirliği teknikleri etkin bir şekilde kullanılacaktır. Bu, modelin hangi özniteliklere dayanarak tahmin yaptığını ve bu özniteliklerin etki yönünü ve büyüklüğünü anlamamıza yardımcı olacaktır.¹¹ Bu şeffaflık, modelin güvenilirliğini artırır ve potansiyel hataların veya istenmeyen davranışların tespit edilmesine olanak tanır.
- **Hesap Verebilirlik:** Proje çıktıları ve geliştirilen modellerle ilgili sorumluluk proje yürütücüsü ve danışmanına aittir. Kodların (uygun ve paylaşılabılır kısımlarının) ve analiz süreçlerinin açık kaynak olarak (örn., bir GitHub deposu üzerinden) paylaşılması, bilimsel topluluk tarafından incelenmesine ve doğrulanmasına olanak tanıyarak hesap verebilirliği artırılabilir ve bu seçenek değerlendirilecektir.

○ **Potansiyel Kötüye Kullanım ve Yanlış Yorumlama Riski:**

- Geliştirilen risk tahmin modelinin, bir araştırma prototipi olmasına rağmen, yanlış yorumlanması veya amaç dışı kullanılması (örneğin, sigorta şirketleri tarafından prim belirlemede ayrımcılık amacıyla, işverenler tarafından işe alım kararlarında veya bireyler tarafından kendi kendine yanlış tanı koyma amacıyla) potansiyel bir risktir. Bu nedenle, projenin çıktılarının bir tanı aracı olmadığı, sadece bir risk değerlendirme ve erken uyarı potansiyeli taşıyan bir araştırma aracı olduğu her aşamada açıkça vurgulanacaktır. Sonuçların her zaman bir tıp uzmanı tarafından diğer klinik bilgilerle birlikte değerlendirilmesi gerektiği belirtilecektir.

○ **Genel Etik Yaklaşım ve İlkeler:**

Proje, insan katılımcılarla ilgili araştırmalar için uluslararası kabul görmüş etik ilkeler olan Helsinki Deklarasyonu'nun ruhuna ve T.C. Sağlık Bakanlığı'nın ilgili yönetmeliklerine (eğer doğrudan insan katılımı olsaydı geçerli olacak prensipler açısından) uygun bir şekilde yürütülecektir. Ayrıca, sorumlu yapay zeka geliştirme ve uygulama prensipleri (örneğin, Avrupa Komisyonu'nun Güvenilir YZ Etik İlkeleri: insan özerkliği ve denetimi, teknik sağlamlık ve güvenlik, gizlilik ve veri yönetimi, şeffaflık, çeşitlilik, ayrımcılık yapmama ve adalet, toplumsal ve çevresel refah, hesap verebilirlik) projenin her aşamasında göz önünde bulundurulacaktır.

Bu etik hususların titizlikle ele alınması, projenin sadece bilimsel ve teknolojik olarak başarılı olmasını değil, aynı zamanda toplumsal değerlere saygılı ve insan odaklı bir yaklaşımla yürütülmesini de sağlayacaktır. Etik değerlendirme, projenin bir yükümlülüğü değil, kalitesinin ve güvenilirliğinin temel bir bileşenidir.

Sonuç

Bu proje önerisi, yapay zeka tekniklerini kullanarak uyku analizi yoluyla kalp krizi riskini tahmin etmeyi amaçlayan kapsamlı bir araştırma ve geliştirme çalışmasını ana hatlarıyla ortaya koymaktadır. Projenin temel amacı, bireylerin polisomnografi (PSG) verilerinden elde edilen zengin fizyolojik bilgileri işleyerek, kalp krizi gibi ciddi bir kardiyovasküler olayın riskini erken aşamada ve non-invaziv bir şekilde belirleyebilen bir model prototipi geliştirmektir.

Literatür, uyku kalitesi ve çeşitli uyku bozuklukları ile kardiyovasküler hastalıklar arasında güçlü bir ilişki olduğunu açıkça göstermektedir.¹ Kalp Atım Hızı Değişkenliği (HRV) ve kan oksijen saturasyonu (SpO2) gibi uyku sırasında ölçülebilen parametreler, bu riskin önemli göstergeleri olarak kabul edilmektedir.⁷

Yapay zeka, özellikle derin öğrenme, bu karmaşık fizyolojik verilerden anlamlı örüntüler çıkararak hastalık tahmininde umut verici sonuçlar sunmaktadır.⁴

Proje, halka açık büyük ölçekli PSG veri setlerini (örn., SHHS, CinC Challenge 2018) kullanarak, kapsamlı bir veri ön işleme ve öznitelik mühendisliği süreci uygulayacaktır. Ardından, hem geleneksel makine öğrenmesi algoritmaları hem de evrişimli sinir ağları (CNN), tekrarlayan sinir ağları (LSTM) ve Transformer tabanlı modeller gibi çeşitli derin öğrenme mimarileri geliştirilecek, eğitilecek ve performansları titizlikle karşılaştırılacaktır. Hedef, yüksek doğruluk ve özellikle yüksek duyarlılık (riskli bireyleri kaçırmama) ile birlikte iyi bir genel ayırt etme gücü ($AUC > 0.80$) elde etmektir.

Projenin önemli bir yenilikçi yönü, model yorumlanabilirliğine (SHAP, LIME gibi tekniklerle) özel bir vurgu yapmasıdır.¹¹ Bu sayede, geliştirilen modellerin "kara kutu" olmaktan çıkarılması ve hangi uyku parametrelerinin kalp krizi riskini tahmin etmede en etkili olduğunun anlaşılması hedeflenmektedir. Bu, hem modelin güvenilirliğini artıracak hem de potansiyel klinik içgörüler sunacaktır.

Projenin beklenen bilimsel katkıları arasında, uyku-kardiyak ilişkisinin daha iyi anlaşılması, farklı YZ modellerinin bu spesifik problemdeki performansının karşılaştırılması ve potansiyel yeni risk belirteçlerinin tanımlanması yer almaktadır. Teknolojik olarak, bir risk tahmin modeli prototipi ve bir analiz süreci geliştirilecektir. Toplumsal ve ekonomik açıdan ise, projenin uzun vadede erken teşhise, kişiselleştirilmiş önleyici tedbirlere ve dolayısıyla sağlık hizmetleri maliyetlerinin azaltılmasına katkıda bulunma potansiyeli bulunmaktadır.

Proje sürecinde karşılaşılabilecek veri erişimi, veri kalitesi, model performansı ve hesaplama kaynakları gibi potansiyel riskler tanımlanmış ve bunlara yönelik çözüm önerileri sunulmuştur. Etik hususlar, özellikle veri gizliliği, algoritmik yanlılık ve şeffaflık konuları, projenin her aşamasında öncelikli olarak ele alınacaktır.

Sonuç olarak, "Yapay Zeka Tabanlı Uyku Analizi ile Kalp Krizi Riski Tahmini" projesi, bilgisayar mühendisliği ve tıp bilimlerinin kesişiminde yer alan, hem bilimsel hem de toplumsal açıdan önemli bir potansiyele sahip, yenilikçi ve titiz bir çalışmadır. Başarıyla tamamlandığında, bu alandaki bilgi birikimine önemli katkılar sunması ve gelecekteki klinik uygulamalar için bir zemin oluşturması beklenmektedir.

Alıntılanan çalışmalar

1. Sleep Prevention and Heart Disease: Everything You Need to Know - UChicago Medicine, erişim tarihi Mayıs 18, 2025, <https://www.uchicagomedicine.org/forefront/heart-and-vascular-articles/how-sleep-deprivation-and-sleep-apnea-impact-heart-health>
2. Sleep Duration as a Risk Factor for Cardiovascular Disease- a Review of the Recent Literature - PubMed Central, erişim tarihi Mayıs 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC2845795/>
3. Uyku Apnesi ve Kalp Hastalıkları: Riskler ve Tedavi Yöntemleri | Medipol Sağlık Grubu, erişim tarihi Mayıs 18, 2025, <https://medipol.com.tr/bilgi-kosesi/adan-zye-saglik/uyku-apnesi-ve-kalp-hastaliklari-riskler-ve-tedavi-yontemleri>
4. The Role of AI in Predicting Heart Disease: Potential and Challenges - CircleDNA, erişim tarihi Mayıs 18, 2025, <https://circledna.com/blog/the-role-of-ai-in-predicting-heart-disease-potential-and-challenges/>
5. TÜRK KARDİYOLOJİ DERNEĞİ, erişim tarihi Mayıs 18, 2025, <https://file.tkd.org.tr/docs/KardiyovaskulerHastaliklardaYapayZeka.pdf>
6. Artificial intelligence to improve cardiovascular population health - Oxford Academic, erişim tarihi Mayıs 18, 2025, <https://academic.oup.com/eurheartj/advance-article/doi/10.1093/eurheartj/ehaf125/8086921>
7. Detection and Severity Classification of Sleep Apnea Using Continuous Wearable SpO2 Signals: A Multi-Scale Feature Approach - MDPI, erişim tarihi Mayıs 18, 2025, <https://www.mdpi.com/1424-8220/25/6/1698>
8. physionet.org, erişim tarihi Mayıs 18, 2025, <https://physionet.org/files/challenge-2018/1.0.0/challenge2018cinc.pdf>
9. AI-powered Analyses in Noxturnal - Nox Medical, erişim tarihi Mayıs 18, 2025, https://noxmedical.com/wp-content/uploads/2024/10/Nox-AI-Handout-for-International-Market_WEB.pdf
10. Sleep heart rate variability assists the automatic prediction of long ..., erişim tarihi Mayıs 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC7281861/>
11. Prediction model of obstructive sleep apnea-related hypertension: Machine learning-based development and interpretation study - PubMed Central, erişim tarihi Mayıs 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC9760810/>
12. TabulaTime: A Novel Multimodal Deep Learning Framework for Advancing Acute Coronary Syndrome Prediction through Environmental and Clinical Data Integration - arXiv, erişim tarihi Mayıs 18, 2025, <https://arxiv.org/html/2502.17049v2>
13. Robust Multitask Sleep Event Monitoring using Multichannel PSG Reconstruction and Inter-channel Contrastive Learning - arXiv, erişim tarihi Mayıs 18, 2025, <https://arxiv.org/html/2504.13229v1>
14. [2503.02124] A Hybrid CNN-Transformer Model for Heart Disease Prediction Using Life History Data - arXiv, erişim tarihi Mayıs 18, 2025, <https://arxiv.org/abs/2503.02124>
15. A Hybrid CNN-Transformer Model for Heart Disease Prediction Using Life History Data - arXiv, erişim tarihi Mayıs 18, 2025, <https://arxiv.org/pdf/2503.02124>
16. AI Model Shows High Accuracy in Heart Attack Detection - American College of Cardiology, erişim tarihi Mayıs 18, 2025, <https://www.acc.org/About-ACC/Press-Releases/2025/03/29/17/21/AI-Model-Shows-High-Accuracy>
17. AI-Driven Technology in Heart Failure Detection and Diagnosis: A Review of the

- Advancement in Personalized Healthcare - MDPI, erişim tarihi Mayıs 18, 2025, <https://www.mdpi.com/2073-8994/17/3/469>
18. Explainable AI Based Coronary Heart Disease Prediction: Enhancing Model Transparency in Clinical Decision Making - bioRxiv, erişim tarihi Mayıs 18, 2025, <https://www.biorxiv.org/content/10.1101/2025.03.20.644456.full.pdf>
 19. Full article: Application of an interpretable machine learning method to predict the risk of death during hospitalization in patients with acute myocardial infarction combined with diabetes mellitus - Taylor & Francis Online, erişim tarihi Mayıs 18, 2025, <https://www.tandfonline.com/doi/full/10.1080/00015385.2025.2481662?src=exp-la>
 20. Multimodal Sleep Stage and Sleep Apnea Classification Using Vision Transformer: A Multitask Explainable Learning Approach - arXiv, erişim tarihi Mayıs 18, 2025, <https://arxiv.org/html/2502.17486v1>
 21. The use of heart rate variability, oxygen saturation, and anthropometric data with machine learning to predict the presence and severity of obstructive sleep apnea - PMC - PubMed Central, erişim tarihi Mayıs 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11949982/>
 22. Yapay zeka teknolojileri kalp hastalığı tanısında "anahtar rol" oynayacak, erişim tarihi Mayıs 18, 2025, <https://www.aa.com.tr/tr/saglik/yapay-zeka-teknolojileri-kalp-hastaligi-tanisinda-anahtar-rol-oynayacak/3468492>
 23. A comprehensive review of machine learning for heart disease prediction: challenges, trends, ethical considerations, and future directions - Frontiers, erişim tarihi Mayıs 18, 2025, <https://www.frontiersin.org/articles/10.3389/frai.2025.1583459/full>
 24. Research on Early Warning Model of Cardiovascular Disease Based on Computer Deep Learning - arXiv, erişim tarihi Mayıs 18, 2025, <https://arxiv.org/pdf/2406.08864?>
 25. Automatic Sleep Scoring: Shaping Future of Sleep Health - Bitbrain, erişim tarihi Mayıs 18, 2025, <https://www.bitbrain.com/blog/automatic-sleep-scoring>
 26. Feature optimized hybrid model for prediction of myocardial infarction - F1000Research, erişim tarihi Mayıs 18, 2025, <https://f1000research.com/articles/14-78/pdf>
 27. A comprehensive review of machine learning for heart disease prediction: challenges, trends, ethical considerations, and future directions - Frontiers, erişim tarihi Mayıs 18, 2025, <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2025.1583459/full>
 28. Transformer-Driven Affective State Recognition from Wearable Physiological Data in Everyday Contexts - MDPI, erişim tarihi Mayıs 18, 2025, <https://www.mdpi.com/1424-8220/25/3/761>
 29. (PDF) Ethical Considerations in AI Healthcare Solutions - ResearchGate, erişim tarihi Mayıs 18, 2025, https://www.researchgate.net/publication/389705420_Ethical_Considerations_in_AI_Healthcare_Solutions
 30. Ethics of AI in Healthcare and Medicine - HITRUST, erişim tarihi Mayıs 18, 2025, <https://hitrustalliance.net/blog/the-ethics-of-ai-in-healthcare>
 31. Uykunun Kalp Sağlığı Üzerindeki Rolü - Prof. Dr. Mustafa Güden, erişim tarihi Mayıs 18, 2025, <https://www.mustafaguden.com/2024/01/15/uykunun-kalp-sagligi-uzerindeki-rolu/>